

华中科技大学

本科毕业设计[论文]

基于 PPG 的睡眠呼吸监测方法研究

院 系 人工智能与自动化学院

专业班级 智能医学工程 2201 班

姓 名 薛卜元

学 号 U202215123

指导教师 葛俊锋

2026 年 4 月 30 日

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的
研究成果。除了文中特别加以标注引用的内容外，本论文不包括任何其他个人或
集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保
留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查
阅和借阅。本人授权省级优秀学士论文评选机构将本学位论文的全部或部分内
容编入有关数据进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学
位论文。

本学位论文属于 1、保密 ☐，在 年解密后适用本授权书。

2、不保密 ☐。

（请在以上相应方框内打“√”）

作者签名： 年 月 日

导师签名： 年 月 日

摘要

阻塞性睡眠呼吸暂停（OSA）是一种高发病率的睡眠呼吸障碍，长期不能得到有效治疗将会显著增大心血管疾病以及猝死的风险。目前临床诊断与治疗上所使用的“金标准”多导睡眠图（PSG）因其成本高昂、依从性大的缺点因而难以覆盖大规模的人群筛查。因此，基于光电容积脉搏波（Photoplethysmography, PPG）的居家自动筛查方法便具有了重要的临床诊断价值。然而目前现有的基于 PPG 的 OSA 检测方法在数据质量、标签粒度以及建模范式三个层面上仍然存在着明显的改进空间：原始数据中未经临床判据确认的事件标注与清醒段噪声降低了训练数据质量；滑窗二值标签丢失了事件在窗口内的覆盖度信息；端到端分类框架无法建模事件的时间局部性，也缺乏临床应用所需的可解释性。

本文以公开的 MESA 数据集为实验平台，提出数据、标签、建模的三级递进优化方案。工作的第一步是依据 AASM 临床标准设计了全新的数据预处理流程（简称为 v2 预处理），对原始数据集中标注的 Hypopnea（呼吸减弱事件）与 Unsure（不确定事件）进行基于 Arousal（微觉醒事件）或者 SpO₂ Desaturation（血氧饱和度下降事件）的二次过滤确认，并结合睡眠分期提取有效睡眠时窗，剔除了约 15% 的假阳性标签与无效负样本。之后引入了软标签以及 10 秒延迟对齐策略，使模型能够学习到时间边界的连续信息。最后构建了基于平滑门控注意力机制的 DSepMIL 多示例学习模型，将滑窗特征视为 60 个时间 instance，通过 AvgPool1d 平滑的注意力聚合强制输出契合呼吸事件物理时长的连续关注波段，并辅以自适应 α 的 ComboFocalF1Loss 与梯度裁剪抑制 mode collapse。此外，本文还构建了基于事件中心采样与 49 维统计特征的机器学习基线作为横向对照。

实验结果表明，所提方法在 5 折 AHI 分层交叉验证下将准确率从基准的 67.74% 提升到 81.34%，AUROC 从 71.92% 提升至 84.96%，被试级 AHI 估计的 Pearson 相关系数从 0.5551 提升至 0.8075，均达到全部实验的最优水平。同时模型的注意力权重可直观指示疑似事件的发生时段，为临床医师提供了事件级的可解释性支撑。本文工作为基于 PPG 的 OSA 居家筛查提供了可靠且可解释的技术方案，对扩大 OSA 人群筛查覆盖面、推动可穿戴睡眠健康监测具有一定的参考价值。

关键词：阻塞性睡眠呼吸暂停；光电容积脉搏波；多示例学习；注意力机制

Abstract

Obstructive Sleep Apnea (OSA) is a highly prevalent sleep-breathing disorder that, if left untreated, substantially increases the risk of cardiovascular diseases and sudden death. While polysomnography (PSG) remains the clinical gold standard, its high cost and poor compliance make it unsuitable for large-scale population screening, creating strong demand for home-based automated screening solutions based on photoplethysmography (PPG). However, existing PPG-based OSA detection methods still exhibit notable limitations at three distinct levels: insufficient clinical-criterion enforcement during data preprocessing leads to label noise and ineffective negative samples; binary sliding-window labels fail to capture the continuous coverage of respiratory events within each window; and end-to-end classification frameworks cannot explicitly model the temporal locality of events and lack the interpretability required for clinical adoption.

Using the MESA dataset as the experimental platform, this thesis proposes a three-stage progressive optimization scheme across the data, label and modeling levels. First, a v2 preprocessing pipeline is designed based on AASM clinical criteria, which re-verifies Hypopnea and Unsure events against subsequent arousal or SpO₂ desaturation and restricts training data to effective sleep periods derived from the sleep-stage annotations, thereby eliminating approximately 15% of false-positive labels and a substantial amount of invalid negative samples. Second, event-coverage soft labels combined with a 10-second delay alignment strategy are introduced to enable the model to learn the continuous boundary information of respiratory events. Third, a DSepMIL model equipped with a smoothed gated attention mechanism is constructed, which treats each sliding window as a bag of 60 temporal instances and enforces continuous attention bands consistent with the physical duration of respiratory events through AvgPool1d-smoothed attention aggregation; a ComboFocalF1Loss with adaptive α and gradient clipping are further adopted to suppress mode collapse during training. In addition, a machine-learning baseline using event-centered sampling and a 49-dimensional handcrafted feature set is constructed as a lateral reference.

Under 5-fold AHI-stratified cross-validation, the proposed method improves the classification accuracy from the baseline 67.74% to 81.34%, the AUROC from 71.92% to 84.96%, and the Pearson correlation coefficient of subject-level AHI estimation from

0.5551 to 0.8075, all achieving the best results across all conducted experiments. Moreover, the learned attention weights directly indicate the probable time segments of respiratory events, providing event-level interpretability to clinicians. The proposed framework offers a reliable and interpretable technical solution for PPG-based home screening of OSA, with meaningful implications for expanding population-level screening coverage and advancing wearable sleep-health monitoring.

Keywords: Obstructive Sleep Apnea; Photoplethysmography; Multiple Instance Learning; Attention Mechanism

目录

摘要	I
Abstract.....	II
1 绪论	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 可穿戴设备与居家筛查.....	2
1.2.2 传统特征工程结合机器学习.....	2
1.2.3 深度学习端到端方法.....	2
1.2.4 低功耗与边缘智能.....	3
1.2.5 研究发展趋势.....	3
1.3 现有方法的不足与改进空间.....	4
1.4 研究目标与主要内容.....	5
1.4.1 研究目标.....	5
1.4.2 本文主要工作.....	5
1.4.3 论文结构.....	6
2 基于 AASM 标准的数据集清洗与标签构建	7
2.1 MESA 数据集与任务概述	7
2.1.1 MESA 数据集介绍	7
2.1.2 任务定义与难点.....	7
2.1.3 三层问题导向的整体技术路线.....	8
2.2 数据清洗.....	9
2.2.1 受试者筛选.....	9
2.2.2 睡眠时间窗口提取.....	10
2.2.3 呼吸事件确认过滤.....	10
2.3 特征预处理.....	11
2.3.1 多通道特征提取.....	11
2.3.2 标签构建策略.....	12
2.3.3 呼吸事件响应延迟的实证分析.....	13

2.3.4 AHI 分层交叉验证.....	15
3 基于特征工程的机器学习方法	17
3.1 研究思路.....	17
3.2 事件中心窗口采样.....	17
3.3 统计特征聚合.....	18
3.4 分类器选择与实验设置.....	19
3.4.1 分类器选择.....	19
3.4.2 评估协议.....	19
3.5 实验结果与案例分析.....	20
3.5.1 定量结果对比.....	20
3.5.2 典型事件的正案例分析.....	21
3.5.3 困难样本的负案例分析.....	22
4 基于深度学习的端到端方法	25
4.1 基准模型与复现.....	26
4.1.1 DSepST15Net 模型结构	26
4.1.2 基准复现结果.....	27
4.2 改进的 v2 数据预处理.....	28
4.2.1 预处理改进动机.....	28
4.2.2 预处理效果验证.....	29
4.3 延迟对齐与软标签优化.....	31
4.3.1 PPG 生理延迟补偿	31
4.3.2 软标签训练策略.....	31
4.3.3 消融实验与分析.....	32
4.4 基于多示例学习的事件级可解释建模.....	34
4.4.1 SIL 的时间局部性与可解释性缺失.....	34
4.4.2 DSepMIL 模型结构	34
4.4.3 ComboFocalF1Loss 损失设计	37
4.4.4 实验结果与可解释性分析.....	38
4.5 综合结果讨论与多维度案例分析.....	41

4.5.1 三阶段改进的定量消融总表.....	41
4.5.2 MIL 注意力的正案例分析	43
4.5.3 MIL 漏检负案例分析	44
5 总结与展望	46
5.1 研究工作总结.....	46
5.2 不足与展望.....	47
参考文献	49
致谢	53

1 绪论

1.1 研究背景与意义

睡眠呼吸障碍是一种在睡眠期间反复出现低通气甚至呼吸暂停的常见疾病，其中阻塞性睡眠呼吸暂停（OSA）最为常见。OSA 患者夜间会反复发生上气道塌陷，导致间歇性低氧、高二氧化碳血症以及交感神经过度兴奋等症状，长期以往将提高高血压、冠心病等心血管疾病发病风险^[1, 2]，并可能伴随认知功能下降、日间嗜睡等症状以及潜在的交通事故风险上升^[3]。在 Benjafield 等基于全球 17 个国家的流行病学数据的统计估计中，30 到 69 岁人群中约有 9.36 亿人患有轻度及以上 OSA，其中约 4.25 亿人为中重度，但绝大部分患者仍有待获得明确的诊断^[4]。庞大的未诊断患者规模与日益凸显的公共卫生负担使得低成本、高可及的 OSA 筛查手段成为亟待突破的研究课题。

目前邻床诊断 OSA 的金标准仍然是夜间多导睡眠监测（PSG），它能在睡眠实验室内同步采集脑电、眼电、肌电、鼻气流、胸腹呼吸努力、脉搏血氧等十余路生理信号，由专业技术人员人工判读每一次呼吸事件并计算呼吸暂停低通气指数（AHI）。PSG 的诊断精度虽然高，但是设备体积大、单次检测费用高昂、需要预约等待、首夜效应（受试者在医院等陌生环境下第一晚的睡眠质量低于日常水平的现象）^[5, 6]等不利因素成为了 PSG 在大规模人群筛查场景中普及的几大掣肘。

光电容积脉搏波（PPG）则为这一困境提供了新的解决思路。PPG 通过发光二极管照射皮下微血管床、光电探测器接收反射光强度，间接测量血容量随心动周期的搏动变化，是目前智能手环手表等可穿戴式智能设备中最常用的生理传感信号之一^[7]。研究表明，呼吸暂停发生时的气流受限与间歇性缺氧可引起自主神经瞬时兴奋、外周血管收缩与心率波动，这些变化会以脉搏波振幅下降、脉搏间期改变、波形形态改变等形式在 PPG 信号中留下可观测的痕迹^[8]。也就是说，单通道 PPG 可以在不依赖额外的外部传感器的前提下，就可以具备反映呼吸时间的基础条件。在此优势的前提下，结合可穿戴设备（如手表、手环、戒指等）的便携性、长续航能力和低成本，基于 PPG 的居家 OSA 筛查有望在 PSG 之外构建一条初筛路径，从而缓解医疗资源紧张问题，并扩大人群筛查覆盖率。

因此,研究基于 PPG 的睡眠呼吸暂停检测方法,不仅对推动可穿戴医疗设备落地具有工程价值,也对降低 OSA 漏诊率具有一定的临床与社会意义。

1.2 国内外研究现状

1.2.1 可穿戴设备与居家筛查

随着智能手表、手环等消费级可穿戴智能产品的普及,利用其内置 PPG 传感器开展居家 OSA 筛查已经成为了临床验证的热点。Chen 等在单中心临床队列上验证了某款国产基于 PPG 进行 OSA 检测的智能手表相对于 PSG 的筛查准确性,并按照三档 AHI 的阈值分别报告了敏感性与特异性,为可穿戴智能产品筛查 OSA 的临床可接受度奠定了证据基础^[9]。Wang 等则在硬件层面进一步整合 PPG 与其他生理传感器,构建了面向 OSA 诊断的无线可穿戴平台^[10]。这些研究者的工作共同表明,为可穿戴智能产品筛查 OSA 在原理与工程上可行,但不同设备、不同人群以及不同阈值下的性能波动仍然明显,模型的泛化能力与受试者的独立验证是当前的瓶颈。

1.2.2 传统特征工程结合机器学习

早期研究沿用分窗、预处理、特征提取、分类器的经典范式,在可解释性方面具有天然的优势。Johansson 等较早地使用神经网络从 PPG 估计呼吸率^[11]; Motin 等提出基于集合经验模式分解与主成分分析(EEMD-PCA)的呼吸率和心率同步估计方法^[12]; Karlen 等提出 Smart Fusion 多参数呼吸率估计框架,将幅度调制、频率调制与基线调制三路特征加权融合^[13, 14]。

在事件检测方向,研究者通过利用 PPG 脉搏波振幅下降与 SpO₂ 下降之间的时滞关系标注窗口,再提取脉搏波形态和变异性特征输入分类器^[15]。这类方法对预处理质量与特征设计依赖较重,在信号质量良好时性能稳定,但在事件边界模糊、部分覆盖或受运动伪影干扰时鲁棒性不足。

1.2.3 深度学习端到端方法

随着深度学习在时序生理信号领域的迅速渗透,基于 PPG 的 OSA 检测已逐渐从人工特征范式转向端到端学习范式。Jothi 等系统比较了 BiLSTM、TCN 及

其组合网络在 OSA 检测中的性能^[16]; Jiang 等提出专门针对 PPG 的 PPG-CNN 模型, 并通过消融实验验证了时序模块的必要性^[17]; Shuzan 等提出 PPG2RespNet, 用于从 PPG 合成高保真呼吸信号, 为下游事件检测任务提供了特征基础^[18]。Charlton 等对 314 种从心电图和 PPG 估计呼吸率的算法组合进行了系统评估, 确立了时域特征与调制融合作为最优路径之一^[19]。

在上述工作的基础上, Choksatchawathi 等于 2024 年提出 ApSense 方法, 是当前基于 PPG 的 OSA 检测领域的代表性工作^[15]。ApSense 以七维脉搏级特征 (PWA、PPI、SPD、DPD、PA 及 dPWA、dPPI) 作为输入, 通过级联的 RVarDSepBlock (深度可分离卷积+变分 LSTM) 提取局部脉搏形态与跨周期时序依赖, 再经 BCNN 融合多尺度表示, 最终经全连接层输出事件级二分类概率。该方法在 MESA 与 HeartBEAT 数据集上以受试者独立划分验证, 总参数量仅约 25.7 万, 约为对比方法 DRIVEN 的 1/80, 具有突出的轻量化优势。由于性能与模型规模的良好权衡, ApSense 已成为后续工作普遍参照的基线, 本文亦以 ApSense 作为基础框架开展改进研究。

1.2.4 低功耗与边缘智能

随着算法落地于可穿戴终端, 算力与能耗约束日益突出。Chen 等提出基于超维计算的轻量框架, 将 OSA 检测所需的功耗降低至适合腕带长时间运行的量级, 体现出精度、能耗、实时性综合权衡的发展趋势^[3]。

与此同时, PPG 信号易受运动伪影、佩戴松紧等因素干扰, 信号质量评估本身亦成为独立研究方向: Guo 等提出基于语义分割的 PPG 伪影检测方法^[20], Pereira 等提出基于监督学习的 PPG 质量评估框架^[21], 这些工作为可穿戴环境下的鲁棒部署提供了技术支撑。

1.2.5 研究发展趋势

综合上述研究现状, 基于 PPG 的 OSA 检测领域正由可行性探索向临床可验证、可部署应用演进, 数据与验证范式趋于严格, 受试者独立划分与 AHI 分级阈值评估正在成为方法学准入门槛^[9, 15]; 模型结构走向复合与多尺度表征, 局部形态特征与跨周期时序依赖的联合建模成为主流^[15, 17, 19]; 鲁棒性与可部署性被同等重视, 抗干扰验证和能耗约束进入核心指标体系^[3, 10]; 评价体系向临床可用

性对齐，在事件级准确率之外越来越关注基于窗口预测聚合得到的预测 AHI 与真实 AHI 的相关性^[9, 15]。

1.3 现有方法的不足与改进空间

尽管以 ApSense 为代表的深度学习方法推动了基于 PPG 的 OSA 检测取得显著进展，但在面向真实筛查场景时，现有工作仍存在若干亟待改进的环节。本文在复现 ApSense 的过程中，结合对 MESA 数据集与误差案例的定量分析，从数据、标签、建模三个层面梳理其主要不足。

首先，在数据方面，预处理流程粗糙导致大量无效或噪声样本。Apsense 所使用的方法普遍对 MESA 原始记录进行整夜切窗，未区分真正的睡眠阶段与入睡前和醒后的清醒时段，导致大量清醒期的样本被直接纳入训练与评估，稀释了负样本的诊断含义；同时，AASM 临床标准^[22]要求 Hypopnea 事件必须伴随微觉醒或血氧下降才能确认为有效低通气事件，同时 Unsure 事件若伴随了 Arousal（微觉醒事件）或 SpO₂ Desaturation（血氧饱和度下降事件）也能被归类于 Hypopnea 事件。但现有工作往往不加区分地将所有标注事件视为正例，引入了显著的标签噪声。

其次，在标签层面，窗口策略单一、硬二值标签丢失事件边界与覆盖信息。ApSense 采用 60 秒固定窗口配合单一二分类标签的方案^[15]，当事件仅覆盖窗口一小部分时，模型被要求以相同置信度输出阳性标签，训练信号与真实事件分布不一致，造成边界模糊样本的学习困难；此外，呼吸暂停事件从发生到引起 PPG 特征响应存在约 10 至 30 秒的生理性延迟^[8, 15]，而固定规则的标签对齐方式难以自适应匹配这一延迟特性。这两项问题也正是开题阶段确立的研究切入点。

另外，在建模层面，端到端分类框架缺乏时间局部性与可解释性。现有的 ApSense 模型本质上是将整个 60 秒滑窗压缩为单一 logit 进行二分类^[15]，既无法显式指出疑似事件的时间段，也未能建模窗口内不同时刻的重要性差异；这一方面限制了模型在事件集中爆发区域的稳定性，另一方面使输出缺乏临床可用的注意力或定位信息，不利于医师进行人工复核。

1.4 研究目标与主要内容

1.4.1 研究目标

针对 1.3 节指出的三个层面不足,本文以 ApSense 的原始论文为基础框架^[15],在公开数据集 MESA 上开展改进研究,围绕数据质量、标签粒度、建模范式三个层面提出一条递进式优化方案,力求在提升检测性能的同时为临床可用性提供更扎实的证据。

为了实现这一目标,首先,提出符合 AASM 临床标准的数据清洗流程,解决原始预处理中的清醒段噪声与未确认 Hypopnea 标签噪声问题,提升训练与评估数据的有效性;其次,引入软标签机制与生理延迟补偿机制,解决窗口标签粒度粗糙与标签-响应时间错位问题,使监督信号更贴近事件真实分布;之后,构建基于平滑门控注意力池化的多示例学习(MIL)模型 DSepMIL 并设计与之匹配的组合损失,解决端到端分类框架在时间局部性与可解释性方面的缺失;最后,在受试者独立的 5 折 AHI 分层交叉验证下系统评估各项改进的独立与联合贡献,除事件级指标外,额外报告预测 AHI 与真实 AHI 的 Pearson 相关系数,以对齐临床筛查评价体系^[9, 15]。

1.4.2 本文主要工作

本文共四个部分,具体安排如下:

首先是基于 AASM 临床标准的数据集清洗与多粒度标签构建。以 MESA 数据集为数据源,按照筛选标准保留 276 名受试者;提取 XML 睡眠分期中第一次入睡到最后一次醒来的区间作为有效分析时段,裁剪清醒段;对 Hypopnea 与 Unsure 事件按 AASM 标准^[22]进行二次确认,仅保留伴随微觉醒或 SpO₂ 下降者;在此基础上同步构建二值与软标签两种粒度标签,为深度学习实验提供统一的数据基础。

其次,进行特征工程机器学习基线构建。以事件中心对齐方式构造 1:1 正负样本,对 7 通道信号提取 7 种统计量得到 49 维特征,分别训练 SVM、决策树、随机森林作为对照基线,明确传统特征工程方法在本任务上的性能上限,为深度学习方法的必要性提供数据支撑。

第三部分是深度学习方法的三级递进改进。以 ApSense 为基准模型复现，依次引入 v2 预处理、延迟对齐与软标签、DSepMIL 与 ComboFocalF1Loss 三阶段改进；通过消融实验解耦各项改进的独立贡献，并基于 MIL 注意力权重对典型正负案例进行可解释性分析。

第四部分是系统评估与案例分析。以敏感性、特异性、AUROC 为核心指标，辅以 Accuracy、F1、被试级 Pearson r，比较各阶段改进效果；最终结果在 AUROC 和 Pearson r 两项指标上均刷新了基准复现的性能上限，AUROC 从 71.92% 提升至 84.96%，Pearson r 从 0.5551 提升至 0.8075，其中 Pearson r 的显著提升意味着方法在被试级 AHI 估计这一最贴近临床筛查价值的任务上具备实用潜力。

1.4.3 论文结构

本论文共分五章，各章内容安排如下：

第一章，绪论，介绍 OSA 筛查的临床背景与社会意义、基于 PPG 的 OSA 检测国内外研究现状、现有方法存在的三个层面不足，并据此提出本文的研究目标与主要工作。

第二章，基于 AASM 临床标准的数据集清洗与多粒度标签构建，介绍 MESA 数据集组成、预处理流程、7 通道特征提取与二值标签/软标签构建、基于 XML 标注的呼吸事件响应延迟实证分析，以及受试者独立的 AHI 分层交叉验证划分方案，并给出全文技术路线图。

第三章，基于特征工程的机器学习方法，以事件中心对齐方式构造 1:1 平衡样本，提取 49 维统计特征，训练 SVM、决策树、随机森林三种分类器并进行定量评估与典型正负案例分析，明确传统方法的表达能力上限。

第四章，基于深度学习的端到端方法，按照基准复现、数据改进、标签改进、建模范式改进四阶段展开。首先复现 ApSense 并通过 delay 与 soft 超参扫描暴露底层预处理瓶颈；进而引入 v2 预处理；再叠加延迟对齐与软标签训练；最终构建 DSepMIL 并通过注意力热力图开展可解释性分析。每一阶段均对应 1.3 节提出的一个层面问题，形成前后呼应的改进逻辑。

第五章，总结与展望，总结本文在数据、标签、建模三个层面取得的改进成果与主要结论，讨论当前工作的局限性，并展望后续研究方向。

2 基于 AASM 标准的数据集清洗与标签构建

2.1 MESA 数据集与任务概述

2.1.1 MESA 数据集介绍

多民族动脉粥样硬化研究(MESA)是由美国国立心肺血液研究所(NHLBI)资助的前瞻性纵向队列研究。MESA Sleep Ancillary Study 子项目在主队列 2010-2013 年随访期间为志愿者进行了一次整夜 PSG 采集,数据通过美国国家睡眠研究资源平台(NSRR)开放共享。由于其规模大、人群代表性强、标注质量高,已成为基于 PPG 的 OSA 检测研究中被广泛使用的公开评测基准^[15]。

MESA 的每份整夜记录包含十余路同步生理信号^[6],本文实验涉及其中三路:PPG 光电容积脉搏波,采用红光波长采集,原始采样率为 256Hz;指尖 SpO₂ 血氧饱和度序列,采样率为 1Hz;鼻气流信号,与信号同步提供的是 NSRR 标准格式的 XML 标注文件,其中记录了若干类 ScoredEvent:睡眠分期事件(Stages|Stages,取值为 Wake|0、Stage1|1、Stage2|2、Stage3|3 以及 REM|5)、呼吸相关事件(Obstructive Apnea、Central Apnea、Hypopnea、Unsure 等)、微觉醒事件(Arousal)以及血氧去饱和事件(SpO₂ Desaturation),各事件以 Start 与 Duration 两个字段给出起始秒数与持续时长。

为保证信号质量,本文按照 ApSense 工作的做法^[15],仅保留 NSRR 中 PPG 质量评级达到最高等级的 quality=7 且有效记录时长超过 6 小时的受试者。在此基础上叠加本章 2.2 节将要介绍的受试者级筛选规则,最终保留 276 名受试者作为全文实验的数据基础。

2.1.2 任务定义与难点

本文围绕 MESA 数据同时展开两条任务路线,其定义与难点存在本质差异,须在方法评估时加以区分。

事件中心对齐的闭集二分类(机器学习路线):以每个已标注呼吸事件的中心时刻作为锚点截取 60 秒窗口构造正样本,从无事件区域随机等量采样构造负样本,形成 1:1 平衡的分类数据集。该任务设定下正样本都是"事件居中"的典型样本,负样本是明确无事件段,任务边界清晰,其核心难点在于手工统计特征的表

达能力上限,即 49 维全局聚合特征能否充分刻画呼吸事件在 PPG 波形上的微观表现。

连续滑窗检测(深度学习路线):对整夜睡眠时段进行等步长滑窗切割,每个滑窗独立地预测是否为呼吸事件窗口。该任务贴近真实筛查场景,但正样本可能仅覆盖窗口的一小段,负样本中也混杂了部分事件末端或前兆期的信号。其难点层层递进,依次对应 1.3 节提出的三个层面问题:数据质量问题:未经 AASM 确认的 Hypopnea 事件与清醒时段的窗口共同构成训练噪声源;标签粒度问题:硬二值标签无法反映事件在窗口内的覆盖比例与时间局部性;建模范式问题端到端的整窗分类损失忽略了窗口内部结构,也难以为临床提供事件级可解释性。

需要特别指出的是,上述两条路线因任务定义不同,评估指标不可直接比较。事件中心对齐使机器学习路线每名受试者的正样本率恒为 50%,这与真实 AHI 分布严重脱节;而深度学习路线的窗口阳性率本身就正比于该受试者的 AHI。因此本文在第五章汇总结论时,将机器学习视作特征工程方法的性能上限参照,而将深度学习视作真实筛查场景下的候选方案,两者构成相互印证的对照关系而非直接替代关系。

2.1.3 三层问题导向的整体技术路线

基于上述任务定义,本文构建的全文技术路线如图 2-1 所示。路线以 MESA 原始数据为起点,首先在第二章中完成三项核心工作:基于 AASM 临床标准的受试者筛选与呼吸事件过滤;基于 XML 睡眠分期的有效睡眠时窗提取;7 通道脉搏级特征提取与二值、软标签两种粒度的标签同步构建。这些输出以受试者独立的 5 折 AHI 分层采样划分保存为 pickle 格式,作为第三、四章共同的数据接口。

整篇研究的方法学路线由 1.3 节提出的三层不足直接驱动。数据层面的清醒段噪声与未确认 Hypopnea 标签,标签层面的硬二值粒度与未补偿的响应延迟,建模层面的单 logit 输出与时间局部性缺失。后续各章的工作可看作针对这三层不足分别给出的对应解决方案,并在 ML 与 DL 两条路线下做相互印证的对照实验。整体结构如图 2-1 所示。




图2-1 三层不足与对应改进方法的整体技术路线图

2.2 数据清洗

2.2.1 受试者筛选

从 NSRR 原始发布的约 2000 条 MESA Sleep 记录出发, 本文的受试者筛选依次应用以下三级规则。

首先是信号质量与时长门槛方面, 沿用 ApSense 的筛选标准^[15], 仅保留 PPG 信号质量评级为最高等级的 $quality=7$ 且有效记录时长超过 6 小时的受试者。该规则从源头上剔除了信号丢失、电极脱落、噪声严重以及记录时长不足的样本, 避免信号质量问题被误归因为模型性能缺陷。

其次是文件完整性检查, 对上一步保留的每一位受试者, 分别在 NPZ 信号目录和 XML 标注目录中检查其 PPG 通道、SpO₂ 通道、睡眠分期与呼吸事件标注是否齐全, 缺任一项则整体剔除。

最后是睡眠时窗有效性检查, 解析 XML 中的 Stages|Stages 事件序列, 若某受试者整夜未出现任何非 Wake 分期, 也就是从未进入睡眠, 则无法定义有效分析时段, 予以剔除。该情形在实际数据中极为罕见。

经上述筛选后, 最终保留 276 名受试者作为全文实验的研究对象。

2.2.2 睡眠时间窗口提取

在 ApSense 的原始流程中^[15], 预处理阶段采用的是首尾各去掉 30 分钟的固定规则来近似剔除入睡前和苏醒后的清醒段。该方案实现简单但存在明显局限: 对实际入睡慢、睡前躁动时间长的受试者, 30 分钟不足以覆盖完整清醒期, 大量纯清醒信号仍被纳入训练; 反之对入睡快的受试者, 又会过度裁剪, 损失有效睡眠数据。这种粗糙的策略直接在负样本中引入了与 OSA 判别无关的背景噪声, 稀释了模型的学习信号。

本文借助 XML 标注中已有的睡眠分期结果, 将清醒段裁剪从时间固定裁剪改为基于分期的精准裁剪。具体而言, 遍历所有 EventType 为 Stages|Stages 的 ScoredEvent, 将其 EventConcept 中包含 Wake 或以|0 结尾的分期视为清醒, 其余 (Stage1/2/3、REM) 视为睡眠。然后从中定位两个参数: sleep_onset: 第一个非 Wake 分期的 Start; sleep_offset: 最后一个非 Wake 分期的 Start 和 Duration。

仅保留时间区间[sleep_onset,sleep_offset]内的 PPG、SpO₂ 与呼吸事件数据用于后续窗口切割。这一简单改动在逻辑上对应"只分析受试者真正处于睡眠的时段", 与 AASM 临床指南中计算 AHI 时的总睡眠时间 (Total Sleep Time, TST) 口径相一致, 既消除了清醒段背景对负样本分布的污染, 也使后续 AHI 计算中的分母回归为真实 TST, 提高了 AHI 估计的可信度。

2.2.3 呼吸事件确认过滤

MESA 的 XML 标注中, 呼吸相关事件主要包括 Obstructive Apnea、Hypopnea 以及少量标注员无法判定的 Unsure 事件。这些事件并非在临床意义上同质。Apnea 类事件 (气流完全阻断 ≥ 10 秒) 的判定标准明确且单一; 而 Hypopnea 的 AASM 临床定义^[22]则要求气流下降 $\geq 30\%$ 且持续 ≥ 10 秒, 并满足伴随血氧去饱和 $\geq 3\%$ 或伴随微觉醒的附加条件之一。Unsure 事件则是标注员对气流下降形态存疑的保留判断。

ApSense 原始预处理较为简单^[15], 将 EventConcept 中包含 Apnea 或 Hypopnea 的事件不加区分地全部纳入正样本。这种做法等价于把所有疑似 Hypopnea 都视

为真性事件，引入了不符合 AASM 标准的假阳性标签，直接破坏了监督学习的信号质量。

所以为了对齐临床判据，本文设计了一系列事件确认规则。对于 Obstructive Apnea 类，判定标准明确，直接保留为有效事件；对于 Hypopnea 与 Unsure 类，统一作为候选事件。借助 XML 中事件默认按时间顺序排列的特性，检查该事件在 ScoredEvent 列表中的紧随其后的下一条事件的 EventConcept。若为 Arousal 或 SpO₂ Desaturation，则视为满足 AASM 附加条件，确认为有效事件；否则拒绝该事件，不纳入正样本。

在 276 名受试者上执行该过滤规则的统计结果表明，约 15% 的原始 Hypopnea/Unsure 事件未通过附加条件检查而被拒绝，对应的滑窗被重新归入负样本。这一改动在不丢失任何真正的 Obstructive Apnea 信息的同时，显著提升了正样本集的临床纯度。

2.3 特征预处理

2.3.1 多通道特征提取

为与 ApSense 基线保持可比，本文沿用其定义的 7 通道脉搏级形态特征体系^[15]，对每个滑动窗口内的 PPG 信号计算以下七类特征：

表2-1 PPG信号的7类特征

通道	物理含义
PWA	脉搏波振幅（峰值与前一谷值的幅度差）
SPD	收缩相时长（谷到峰的样本间隔）
DPD	舒张相时长（峰到下一谷的样本间隔）
PA	脉搏面积（谷到峰之间的信号积分）
PPI	峰峰间期（相邻峰值间的时间差，毫秒）
dPWA	PWA 的一阶差分，反映振幅变化率
dPPI	PPI 的一阶差分，反映心率变异性

具体的提取流程依次包括：信号净化：使用 neurokit2.ppg_clean^[23]对原始 PPG 完成滤波与基线校正，再以 2 阶 Chebyshev II 型高通滤波（截止频率 20Hz）进

一步去除低频漂移；峰值检测：使用 `neurokit2.ppg_findpeaks` 在净化信号上检测主峰位置得到 PPI 序列^[23,24]；谷值与二次峰检测：对净化信号再做一次滑动平均去毛刺，同时用 `scipy.signal.argrelextrema`^[25]检测局部最小值与局部最大值，并丢弃相邻样本差小于 30 的密集波动点，消除伪波动造成的虚假峰谷对；形态特征计算：对每一对谷峰依次计算 PWA、SPD、DPD、PA 四项形态量，并在最外层组合 PPI、dPWA、dPPI 得到 7 通道原始序列；等长重采样：由于不同受试者、不同窗口内的心跳数不同，原始特征序列长度不一。将每一通道重采样为固定长度 60，最终每个窗口被统一编码为形状(7,60)的 float32 张量，与 ApSense 网络输入接口一致。

在滑窗层面，本文采用 60 秒窗口+50%重叠（步长 30 秒）作为默认配置，这也是 ApSense 原始论文与本文实验共用的设定^[15]。此外引入两项数据级质量控制：SpO₂ 下限过滤（窗口内 SpO₂ 最小值<60 的窗口视为硬件伪影整窗剔除）与 PPG 有效长度过滤（实际采样点数不足的窗口剔除），进一步降低极端异常样本对训练稳定性的影响。

2.3.2 标签构建策略

对每个已切割的滑动窗口，本文同步构建两种粒度的标签，以供第四章深度学习阶段不同实验使用。

首先是默认的二值标签，以窗口起始秒为零点，逐秒检查该秒是否被任何已确认呼吸事件覆盖，得到长度为 `win_size` 的 0/1 数组。该表示保留了秒级时间信息，既可取最大值得到整窗二分类标签供基准 ApSense 与第三章 ML 使用，也为第四章 MIL 模型在 60 个时间 `instance` 上的监督提供潜在接口。

其次是软标签，它在二值数组的基础上进一步计算窗口内事件秒数的覆盖比例 $\text{ratio} = \text{sum}(\text{binary}) / \text{win_size} \in [0,1]$ ，并将整个标签数组填充为该统一浮点值。软标签的含义是本窗口有多大比例属于事件区间，在极端情形下，事件完全覆盖窗口退化为 1，无事件退化为 0，与二值标签兼容。

两种标签在数据结构上保持一致的数组形状，仅取值不同；软标签在事件仅部分覆盖窗口的边界样本上提供了更贴近事件真实分布的连续监督信号，避免了模型被强制学习部分覆盖=完全事件的错误映射。

此外,在标签构建策略中还预留了 `delay_sec` 参数,用于将事件时间戳整体向后偏移若干秒再计算覆盖,以补偿 PPG 对呼吸事件响应的生理性延迟^[8, 15]。

2.3.3 呼吸事件响应延迟的实证分析

在之后的深度学习实验中,`delay_sec` 是一个关键超参数,其取值直接影响标签时间轴与 PPG 特征响应的对齐精度。然而在实际取值前,还需要弄清楚在 MESA 数据集自身的标注中,呼吸事件与其后续生理响应之间的时间差分布机制。需先从数据层面回答这个问题,便可为第四章的网格搜索划定合理的先验范围,避免纯粹基于实验试错的盲目搜索。

从生理机制上说,呼吸暂停事件一旦发生,其可观测响应通过两条生理通路显现^[7, 8, 15]。其一是 SpO_2 去饱和通路,气流受限使肺泡氧分压下降,经血液循环传导至外周组织的 SpO_2 检测位点存在约 10 到 30 秒的循环时延,因此 SpO_2 下降通常在事件发生后一段时间才被记录到;其二是微觉醒(Arousal)通路,低氧与高二氧化碳血症触发化学感受器反射性唤醒,伴随交感神经兴奋与短暂血压、心率上升。Arousal 的触发时间通常晚于 SpO_2 去饱和,对应的延迟更长。




图2-2 呼吸暂停事件与PPG响应的时序关系

上述两条通路的响应共同塑造了 PPG 信号的可观测变化,因此呼吸事件响应延迟并非单一确定值,而是取决于响应通路、事件类型和受试者个体差异三者的共同作用。

从统计方法上来说,基于上述机理,本文对 NSRR 标注中呼吸事件到最近一次 Arousal 或 SpO₂ Desaturation 的时间差进行全量统计。首先对 276 名受试者的 XML 文件依序解析,仅保留满足 2.2.3 节确认规则的呼吸事件;对每一例确认事件,在其后 90 秒时间窗内查找首次出现的 Arousal 与 SpO₂ Desaturation,分别记录其起始时刻;定义两个指标:delay_from_start(响应起始到事件起始,反映从事件开始到响应被记录的总时延)与 delay_from_end(响应起始到事件结束,反映响应相对于事件尾端的时序关系,可为负表示响应在事件仍在进行时已经启动)。由此,得到了 76534 条事件-响应配对记录。

表2-2 呼吸事件响应延迟总体统计

指标	均值 (s)	标准差 (s)	p25 (s)	中位数 (s)	p75 (s)
delay_from_start	26.70	22.62	15.20	21.30	32.60
delay_from_end	3.89	23.68	-5.30	0.40	7.30

表2-2 响应起始-事件起始的响应通路分组统计

事件类型	响应通路	n	中位数延迟 (s)	均值延迟 (s)
Obstructive Apnea	SpO ₂	7019	21.1	23.0
	Arousal	5520	32.4	35.6
Hypopnea	SpO ₂	38535	17.8	21.0
	Arousal	25460	28.5	34.3




图2-3 响应起始-事件起始延迟分布直方图

基于以上的统计数据可以发现：延迟的主体分布在 10 到 30 秒区间内，`delay_from_start` 的中位数为 21.3s，p25 至 p75 区间为 15.2s 到 32.6s，[10,30) 累计占比达 61.6%，峰值桶在 [15,20)s (21.00%)，这一分布与文献中报道的循环时延 (10 到 30s) 高度一致^[8]。

同时， SpO_2 去饱和响应早于 Arousal，两种事件类型下， SpO_2 Desaturation 相对事件起始的中位数延迟均在 17s 到 22s 范围内，而 Arousal 相对事件起始的中位数延迟均在 28s 到 33s 范围内，晚约 10s，这与上述生理机理中血氧先响应、Arousal 后触发的通路顺序相吻合。

并且，`delay_from_end` 中位数接近零，说明大量响应与事件重叠。`delay_from_end` 中位数 0.40s、p25 为 -5.3s，意味着约一半的响应在事件仍在进行时已经启动。这一现象与 AASM 的 Hypopnea 临床定义（气流下降期间即伴随血氧下降）直接对应。

最后，分布存在明显长尾。超过 30s 的延迟累计占 28.8%，其中 [60,90)s 仍占 8.31%。在有这一长尾的情况下，单一固定延迟值不可能完美对齐所有事件，任何基于固定延迟值的预处理都会存在偏差。这一事实将会反过来支持第四章引入的软标签与 MIL 注意力机制，两者都不要要求标签与信号精确对齐，而是让模型从大致对齐的监督信号中自适应学习事件的时间位置。

2.3.4 AHI 分层交叉验证

为确保评估结果真实反映模型的泛化能力，本文严格遵循受试者独立划分原则，即同一受试者的所有滑窗不可跨越训练集和测试集的边界，避免受试者内部信号相似性导致的性能虚高。

具体到划分本身，第一步是给每位受试者贴上严重度标签：用经 AASM 二次确认的事件总数，除以提取的有效睡眠时长(小时)，即得到该受试者的个体 AHI；再以 $\text{AHI} > 15$ 这一 AASM 重度 OSA 临床诊断阈值^[22]，把所有人分为重度与非重度两组。这一阈值并非任意挑选，它既符合 AASM 临床指南，也是 ApSense^[15] 和 Chen^[9] 等智能手表验证工作共同采用的分级点，沿用相同标准便于后续指标的横向对比。

第二步是在受试者层面做分层采样。本实验调用 `sklearn.model_selection.StratifiedShuffleSplit`^[26] 共抽取 5 次 90:10 的划分，每一折

都保持训练集与测试集中重度、非重度的比例与全体一致。此处选用的是 `StratifiedShuffleSplit` 而非更常见的 `K-Fold` 出于两点考虑, 其一, 276 人这个体量本就不大, 硬性切成 5 个互斥 `fold` 后每折的重度受试者人数会少到使分层效果近乎失效; 其二, `ApSense` 原文同样采用随机抽样协议, 沿用相同方式可让本文实验结果与之直接对照而无需额外校正^[15]。

划分结果按折以 `pickle` 形式落盘, 整个划分过程在固定随机种子下完全可复现。第三、四章的所有实验, 无论是传统机器学习还是深度学习方法, 都建立在同一套 5 折划分之上, 因此后续看到的所有性能差异都只能归因于方法本身, 与数据切分无涉。

3 基于特征工程的机器学习方法

3.1 研究思路

在系统铺开深度学习方法之前,本章先用一条相对成熟的传统机器学习路径在同一份数据集上跑出基线结果作为参照,刻画出特征工程方法在理想任务设定下能走多远,以加深第四章深度学习部分的论证。

首先是探究 PPG 信号的可分性。深度学习固然能给出高 AUROC 数字,但若没有一个手工特征加经典分类器的对照点,便无从知晓这一高数字到底来自于模型的表征能力还是仅仅来自足够大的容量加上数据拟合。手工统计特征配合 SVM、决策树、随机森林这一套组合在信号处理与医学诊断领域已有数十年的积累^[7,11],把它们的表现视作人类先验知识在该任务上能达到的水平上限是相对公允的。

其次是探讨引入深度学习方法是否必要。如果手工特征已经能把性能推到接近上限,那么深度网络换来的复杂度与可解释性代价便难以自洽。本章在与第四章相同的 5 折划分上进行实验,最终量化结果显示统计特征方法的 AUROC 约 73%,而第四章最后在引入多示例学习后达到 84.96%,二者之间约 12 个百分点的差距让深度学习的引入有了基于数据的依据,而不是停留在看起来更先进的修辞层面。

最后还需要说明的是,虽然机器学习与深度学习同在相同的 5 折划分上进行实验,但是由于机器学习方法面对的任务是事件中心对齐的闭集二分类,正样本严格以事件为锚点居中,负样本来自明确的无事件段,任务边界清晰;而深度学习方法面对的是连续滑窗检测,必须处理事件边界模糊、部分覆盖、集中爆发等真实筛查场景。所以两者的 F1、Sensitivity 等与样本比例相关的指标不能直接横向比较。

3.2 事件中心窗口采样

闭集二分类的任务定义要求正负样本本身具有清晰边界,因此采样策略必须在数据层面就把正样本、负样本和边界样本严格分开,正负样本进入训练集,而

边界样本被抛弃。本章在第二章 v2 预处理的基础上构造样本,从而保证受试者集合与事件过滤规则与第四章完全一致,与第四章的差别仅出现在采样策略本身。

正样本以事件为锚点居中构造。对每一例经 AASM 确认的呼吸事件,先算出事件中心,再向两侧各延伸 30 秒得到 60 秒窗口。如果该窗口越出 2.2.2 节提取的睡眠时窗,则整窗丢弃。MESA 中绝大多数呼吸事件持续 10 到 40 秒,事件居中后整段事件本体都恰好位于窗口正中,不会因边界截断而丢失关键信号段。这样得到的正样本集时间结构高度一致,事件不再是位置随机的变量,后续 49 维统计特征的聚合才有相对稳定的语义参考系。

负样本则从无事件区域随机采集。在睡眠时窗内均匀抽取候选 60 秒窗口,但要求该窗口与任何已标注事件不存在任何的时间交集,只要发生重叠就直接拒绝并重抽,反复采样直至累计的负样本数与正样本相等。这一约束的目的是防止非事件但紧贴事件边缘的信号被误归为负样本。这一类信号往往已经携带了上游事件的余波,混入负类会模糊真正的判别边界。1:1 平衡采样则让传统分类器不必遭遇严重的类别失衡,对以 Accuracy、F1 为训练目标的模型尤其重要。

不论正样本还是负样本,最终都通过与 2.3.1 节完全相同的方法生成形状为 (7,60) 的多通道特征张量。这意味着第三章与第四章的输入特征严格同源,差异仅出现在下游。第四章把张量直接送入端到端网络,本章则进入 3.3 节将介绍的统计聚合管线。窗口级的两道质量控制 ($SpO_2 \geq 60$ 、PPG 有效采样长度足够) 也一并沿用,把硬件伪影样本拦在训练集之外。

3.3 统计特征聚合

深度学习方法可直接消费 (7,60) 的时序张量作为输入,而经典机器学习分类器 (SVM、决策树、随机森林) 则要求固定长度的一维特征向量作为输入。本章对每个窗口的 7 通道时序特征分别应用 7 种统计量聚合。

这 7 种统计量覆盖了水平、波动、极端、分位四个维度,兼顾对平稳段与突发波动的描述能力。每个通道经聚合得到 7 个标量,7 个通道共得 $7 \times 7 = 49$ 维一维特征向量。实现层面进一步包含 NaN/Inf 过滤,避免少数通道因特征提取异常产生的无穷值破坏分类器训练。

表3-1 时序特征的7种统计量

统计量	含义
mean	通道信号在窗口内的均值水平
std	通道信号在窗口内的波动幅度
max	窗口内极大值（反映最高峰事件）
min	窗口内极小值（反映最低谷事件）
median	鲁棒性中心位置（对异常值不敏感）
p25	下四分位，刻画低端分布
p75	上四分位，刻画高端分布

3.4 分类器选择与实验设置

3.4.1 分类器选择

本章从医学信号分类领域反复用过的工具里挑了三种性质互补的分类器，SVM（RBF 核）^[27]能拟合复杂非线性边界，RBF 在高维空间中自行构造非线性决策面、单棵决策树^[28]在高维连续特征上几乎注定过拟合、以及随机森林^[29]这一表格类任务的传统强基线。三者容量与稳定性上拉开梯度，用来勾勒 49 维统计特征所能支撑的性能区间。

3.4.2 评估协议

为确保机器学习与深度学习两条路线的结果可在相同数据划分下直接比较，本章严格复用 2.3.4 节定义的 5 折 AHI 分层交叉验证协议，以受试者为划分粒度，按 AHI>15 作为分层标签。每一折内，训练集与测试集分别由训练受试者与测试受试者的全部事件中心窗口串联而成，保证同一受试者不跨集泄露。

评估指标包括 Accuracy、F1、Sensitivity、Specificity、AUROC 以及受试者级 AHI 估计的 Pearson 相关系数。为避免重复定义，下文统一给出各指标的形式化表达。

设测试集上每个样本的真实标签为 $y_i \in \{0,1\}$ 、二值化预测为 $\hat{y}_i \in \{0,1\}$ 、阳性概率为 $\hat{p}_i \in [0,1]$ ，由混淆矩阵得 TP、FP、TN、FN 四量。则：

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (1)$$

$$Sensitivity = \frac{TP}{TP + FN} \quad (2)$$

$$Specificity = \frac{TN}{TN + FP} \quad (3)$$

F1 分数本文采用 macro-F1，即对正类与负类分别计算 F1 后取等权平均：

$$F1_c = \frac{2 \cdot Precision_c \cdot Recall_c}{Precision_c + Recall_c}, c \in \{0,1\} \quad (4)$$

$$macro-F1 = \frac{1}{2}(F1_0 + F1_1) \quad (5)$$

AUROC 定义为 ROC 曲线下面积^[30]，等价于随机抽取的正样本得分高于随机抽取的负样本的概率，其中 $\mathcal{P}$ 、 $\mathcal{N}$ 分别为正、负样本下标集， N_+ 、 N_- 为其数量：

$$AUROC = P(\widehat{p}_{i^+} > \widehat{p}_{i^-}) = \frac{1}{N_+ N_-} \sum_{i^+ \in \mathcal{P}} \sum_{i^- \in \mathcal{N}} 1[\widehat{p}_{i^+} > \widehat{p}_{i^-}] \quad (6)$$

受试者级 Pearson r 用于衡量被试级 AHI 估计能力，对测试折中每位受试者 s，以其测试窗口的预测阳性率 $\widehat{AHI}_s = \frac{1}{|W_s|} \sum_{i \in W_s} \widehat{y}_i$ 作为 AHI 预测值，与真实 AHI_s 配对，跨 5 折汇总所有受试者后统一计算：

$$r = \frac{\sum_s (AHI_s - \overline{AHI}) (\widehat{AHI}_s - \overline{\widehat{AHI}})}{\sqrt{\sum_s (AHI_s - \overline{AHI})^2} \cdot \sqrt{\sum_s (\widehat{AHI}_s - \overline{\widehat{AHI}})^2}} \quad (7)$$

3.5 实验结果与案例分析

3.5.1 定量结果对比

表3-2 机器学习基线方法性能对比（均值±标准差）

分类器	Acc	F1	Sens	Spec	AUROC	Pearson r
SVM	67.57±	68.30±	69.90±	65.23±	73.28±	0.1626
	1.09	1.11	2.21	2.75	1.65	
决策树	57.72±	58.52±	59.65±	55.78±	57.72±	0.1251
	0.92	0.67	0.96	2.05	0.92	
随机森林	67.09±	68.83±	72.71±	61.48±	72.87±	0.2009
	1.58	1.39	2.60	3.77	1.61	

三种分类器在 5 折 AHI 分层交叉验证下的性能汇总如表 3-1 所示。

由表格中数据可知, SVM 与随机森林在主要指标上几乎打成平手, 随机森林 $F1=68.83\%$ 、 $Sens=72.71\%$ 居首, SVM 在 $Specificity$ 上反过来略胜一筹, 但两者 AUROC 仅差 0.41 个百分点。两个性质完全不同的强分类器在同一份特征上得到几乎一致的 AUROC, 说明性能瓶颈已经不在分类器侧, 而在 49 维全局统计特征本身的表达能力, 再换更复杂的分类器也很难有实质提升。同时这一事实也说明了可学习深度特征提取器的必要性, 把统计聚合换成端到端学习的特征, 深度学习方法在同一份数据上把 AUROC 从约 73%推到 84.96%, 那 12 个百分点正是表达能力升级带来的实际增量。

决策树的表现则从反方向佐证了上述结论。它的 AUROC 仅有 57.72%, 单棵决策树在 49 维连续特征上严重过拟合训练集, 到测试集上已经基本不具备判别能力, 几乎只能靠猜。把这棵树放进 20 棵的随机森林里做 bagging 集成、再叠加特征子采样, AUROC 拉回到了 72.87%, 同样的基学习器, 仅靠集成机制就把性能从近似随机推到与 SVM 持平。

最后, 三种分类器的受试者级 Pearson r 都偏低, 落在 0.12 到 0.20 之间, 远低于第四章深度学习方法所能达到的 0.80 量级, 这是由机器学习方法本身决定的, 机器学习方法采用事件中心 1:1 平衡采样, 每位受试者的测试窗口正负比例都恒为 50%, 无论其真实 AHI 是多少, 模型预测出的阳性率都只能在 50%附近浮动, 完全不能反映真实 AHI 的连续分布; 而深度学习方法则不同, 连续滑窗检测下每位受试者的窗口阳性率天然正比于其 AHI, 因此深度学习方法的 Pearson r 才能拟合到 0.8 这个量级。两种方法的 Pearson r 在两个相互无关的坐标系里, 不能直接对照。

3.5.2 典型事件的正案例分析

为从定性层面理解 ML 方法的有效性边界, 本节选取一例被三种分类器一致高置信识别的典型正样本进行分析。该案例来自受试者 6413 ($AHI=53.21$, 明确的重度 OSA 患者), 事件位于其睡眠阶段第 25811 秒前后, 是一段持续 31.2 秒的呼吸事件, 此事件 XML 标注类型为 **Unsure**, 经 2.2.3 节所确立的规则确认为有效事件。该事件正好覆盖 60 秒窗口的中央段 (14.4~45.6 秒, 约 52%覆盖率), 同步的 SpO_2 序列在这一时段内由 97%跌至 88%、下降幅度高达 9%, 远超 AASM

对 Hypopnea 的 $\geq 3\%$ 下降门槛。三种分类器对该样本的预测概率分别为：随机森林 0.97、SVM0.85、决策树 1.0，对该结论高度一致。




图3-1 ML路线典型正案例的PPG、SpO₂波形

从图 3-1 中可观察到几点典型表现：事件期内 PPG 脉搏波振幅（PWA）出现阶段性明显下降，峰峰间期（PPI）呈现规律性延长，提示交感神经在低氧应激下的反射性兴奋；与之同步的 SpO₂ 在事件起始约 15 秒后开始陡降，恰好落在 2.3.3 节实证统计的事件起始至响应中位延迟 21.3 秒区间内。这种形态鲜明、血氧响应显著的典型重度事件表征，使 49 维统计特征中 PWA 通道的标准差与最小值、PA 通道的中位数等多个维度都与负样本分布显著拉开距离，为分类器提供了充分的判别信号。

该案例验证了当呼吸事件在 PPG 形态层面有清晰可见的振幅扰动、且伴随显著 SpO₂ 去饱和时，49 维全局统计特征的表达能力足以支撑高置信正确分类。

3.5.3 困难样本的负案例分析

负案例对方法局限的揭示则更为重要。本节选取一例被三种分类器一致漏检的困难样本受试者 5308（AHI=15.08，临界中度 OSA），事件位于其睡眠阶段第 22285 秒前后，是一段持续 30.2 秒的 Obstructive Apnea。事件覆盖 60 秒窗口的中央段（15.2~45.4 秒，约 50%覆盖率），同步 SpO₂ 由 97%跌至 89%，下降 8%。但三种分类器对该样本的预测概率却全都落在阴性区间，随机森林 0.005、SVM0.13、决策树 0.0。




图3-2 ML路线漏检案例的PPG、SpO₂波形

此负案例之所以对方法局限的揭示则更为重要，则是因为它的事件本身并非边缘样本。如表 3-2 所示，将负案例的各个事件参数（持续时长、窗口覆盖率、SpO₂ 下降幅度）与上一节正案例的各个事件参数并置，可见三项事件参数几乎完全对等：

表3-3 正案例与负案例的事件参数对比

项目	正案例	负案例
事件类型	Unsure	Obstructive Apnea
事件总时长	31.2s	30.2s
窗口覆盖率	52.0%	50.3%
SpO ₂ 下降幅度	9%	8%
受试者 AHI	53.21（重度）	15.08（临界中度）
RF / SVM / DT proba	0.97 / 0.85 / 1.0	0.005 / 0.13 / 0.0

正负案例在事件层面三项关键参数几乎相同，分类结果却走向两个极端。真正的失败原因不在事件信号本身的强弱，而在 ML 路线在深层结构上的固有约束：一个出现在输入特征的来源选择上，另一个出现在特征聚合的方式上。

首先，49 维统计特征全部从 7 通道 PPG 形态序列聚合而来（PWA、SPD、DPD、PA、PPI、dPWA、dPPI），SpO₂ 通道并不直接参与特征构建，它在整套流程中仅在 2.3.1 节作为窗口质量门控使用，只要 SpO₂ 最小值不低于 60%，分类器从此就再也看不到它的任何变化。这意味着无论 SpO₂ 下降多大，只要 PPG 形态

自身没有给出足够强的扰动信号，统计聚合就无法捕捉事件证据。本案例从图中可清楚看到这一矛盾：虽然 SpO_2 有明确的 8% 去饱和，但同时段的 PPG 脉搏波振幅与峰峰间期变化幅度都相当有限，与事件外的正常呼吸段形态较为接近。这正是重度 OSA 患者 (AHI 53) 与临界中度 OSA 患者 (AHI 15) 在自主神经响应强度上的个体差异在 PPG 上的投射，而 ML 路线的输入体系对这种跨模态的事件证据完全无感。

第二重约束出现在特征聚合的层面。即便单看 PPG，事件期内的局部扰动一旦经过整窗的 mean、std、min、max、分位数聚合，就会被窗口前后大段正常信号稀释。本案例事件仅占窗口 50%，剩余 50% 的正常段对全局统计量的贡献足以掩盖事件期的局部异常。这正是 1.3 节中窗口内时间局部性缺失问题的具体体现，全局聚合无法根据事件位置动态调整特征权重，也无法识别事件恰好发生在窗口中段这一结构性先验。

要同时解开这两道结，恰好对应第四章引入深度学习的两条改进路径。前一道结需要把特征提取从固定统计量替换为端到端可学习，让模型自动发现对事件敏感的局部 PPG 模式，从而摆脱 PPG 形态弱、统计特征无感的瓶颈，这是 4.1~4.3 节深度特征提取器要承担的任务；后一道结需要把整窗压缩换成多示例学习，把 60 秒滑窗拆分为多个时间 instance、通过注意力机制显式建模事件的时间位置，让模型能放大事件期的局部扰动而不被窗口其余部分稀释，这是 4.4 节 DSepMIL 的核心动机。换言之，本案例所暴露的两层困难，单模态信号不足与全局聚合丢失局部性将会是第四章 DSepMIL 模型重点攻克的对象。

4 基于深度学习的端到端方法

第三章证实, 基于 49 维全局统计特征的经典机器学习方法在事件中心对齐任务上的 AUROC 上限约为 73%, 且无法刻画事件在窗口内的时间局部性。本章围绕连续滑窗检测任务, 按基准复现、数据改进、标签改进、建模范式改进四个递进阶段展开深度学习方法研究, 依次回应 1.3 节提出的数据、标签、建模三个层面的不足。每一阶段在保持其余设置完全不变的前提下, 仅引入一项改进, 从而以严格的控制变量对比形式, 为各项改进的独立贡献与协同效应提供定量证据。

全章的主要实验配置在此统一说明: 所有深度学习实验均在受试者独立的 5 折 AHI 分层交叉验证下进行(划分协议见 2.3.4 节), 训练优化器为 Adam (初始学习率 1×10^{-3})^[31], 批大小 1024, 最大 epoch 数 10000 并配合 30epoch 验证集 loss 不下降的早停策略; 输入数据为(7,60)的 7 通道脉搏级特征张量, 逐通道 StandardScaler 标准化, 标准化器由训练折拟合后保存, 测试折直接复用以杜绝数据泄漏; 评估指标除 Acc、F1、Sensitivity、Specificity、AUROC 外, 额外报告以受试者为单位计算的 Pearson 相关系数 r (预测窗口阳性率与真实 AHI 的线性相关性, 越接近于 1 越好), 用以衡量被试级 AHI 估计的临床可用性。所有数值以均值 $\pm$ 标准差的形式跨 5 折汇报。




图4-1 深度学习方法四阶段递进改进流程图

4.1 基准模型与复现

4.1.1 DSepST15Net 模型结构

本文选用 ApSense 工作中提出的 DSepST15Net 作为基准深度学习模型^[15], 其设计动机是同时捕捉 PPG 信号在脉搏级(局部形态)与跨脉搏级(时序变异)两个尺度上的特征。本文复现的具体变体为 ApSense 论文 Table II 中报告的 MESA 数据集最优配置 DSepST15Net_no_branch, 即四阶段堆叠+变分 Dropout LSTM、不启用分支卷积(BCNN)。模型主体由 4 个递进的 Backbone 阶段组成, 每阶段包含 4 个 RVarDSepBlock 与一次时间维 AvgPool (步长 2) 下采样, 通道数依次为 64-32-16-8, 时间步长依次为 60-30-15-7, 最后一阶段 AvgPool 后取整为 3, 最终 flatten 维度为 $8 \times 30 = 240$ 。




图4-2 DSepST15Net网络结构示意图

每个 RVarDSepBlock 的核心是一个深度可分离卷积+残差连接^[32]+变分 Dropout LSTM 的组合: 先以 groups=in_channels 的深度卷积(kernel=3,padding=1)按通道分别提取局部形态, 再经 BatchNorm-ReLU 与 1*1 逐点卷积完成跨通道信息融合^[33], 最后将卷积输出以(B,T,C)形式送入隐藏状态维度等同于输出通道数的

LSTM 进一步建模时序依赖。深度可分离卷积相对于标准卷积可将参数量近似降低 $k*k$ 倍, 是该模型轻量化的关键来源^[34]。LSTM 部分采用变分 Dropout 实现, 即在同一序列内的所有时间步上共享同一 dropout 掩码, 从而避免标准 dropout 在 RNN 上每步独立丢弃导致的隐藏状态噪声问题^[35, 36]。

四阶段输出经 flatten 后送入两层全连接 (240-240-1) 输出单一 logit, 整体可视为一个逐窗口的二分类器, 将 60 秒滑窗压缩为单一阳性概率。模型总参数量约 25.7 万, 相对其他 PPG-OSA 检测方法的优势在于参数量-性能比的良好权衡^[15]。

4.1.2 基准复现结果

为了排除模型结构理解偏差对后续改进归因的干扰, 本节首先在原始预处理流程下 (对应 delay0_win60_soft0 配置, 即无时延+60s 窗口+硬标签) 完整复现 ApSense 的训练-评估流程。复现结果为 $\text{Acc}=67.74\pm2.61\%$ 、 $\text{F1}=55.95\pm0.92\%$ 、 $\text{AUROC}=71.92\pm1.75\%$ 、 $\text{Pearson } r=0.5551$, 与 ApSense 原文报告的 MESA 结果 $\text{Acc}=75.10\pm2.70\%$ 、 $\text{F1}=65.73\pm4.84\%$ 、 $\text{AUROC}=77.64\pm7.93\%$ 存在约 7 到 8 个百分点的系统性差距^[15]。

为定位差距来源, 本文在保持模型与训练协议不变的前提下, 对 delay_sec (时延) 与 soft_label (软标签) 两类标签级超参分别进行了网格扫描。

表4-1基准模型在不同delay超参下的性能 (原始预处理、固定win60、soft0)

配置	Acc(%)	F1(%)	Sens(%)	Spec(%)	AUROC (%)	Pearson r
原文	75.10±2.70	65.73±4.84	61.71±17.4	78.46±1.62	77.64±7.93	未给出
基线						
delay0	67.74±2.61	55.95±0.92	64.29±5.69	68.19±3.64	71.92±1.75	0.5551
delay10	66.62±3.07	55.44±1.36	66.33±5.77	66.63±4.18	72.22±1.90	0.6226
delay15	67.37±3.07	55.10±0.59	60.37±3.26	68.37±1.82	69.78±1.47	0.5978
delay20	67.82±3.65	54.99±1.26	58.78±9.44	69.14±5.53	69.95±2.42	0.5312
delay30	66.20±2.75	53.87±1.64	58.09±4.02	67.35±3.28	68.00±2.55	0.5537

观察表 4-1 可见, 五档配置 Acc 全部落在 66%到 68%的窄带内, AUROC 也仅在 68~72%之间小幅起伏, 相邻档位差异普遍小于两个标准差。这一观察提示

delay 对齐在原始预处理下几乎没有显著收益。但若聚焦在对决策阈值不敏感的 AUROC 与 Pearson r 两项指标, delay10 是该网格中表现略优者: AUROC 达到 72.22% (最高)、Pearson r 达到 0.6226 (最高, 相比基线 delay0 上升 0.067)。这一选择也与 2.3.3 节实证统计的事件至响应延迟主体落在 10 到 30s 区间的生理先验落在同一量级 (10s 接近响应分布的下沿), 故选定 delay10 进入第二阶段。

表4-2 固定delay10后的软标签性能验证 (原始预处理、固定win60)

配置	Acc(%)	F1(%)	Sens(%)	Spec(%)	AUROC (%)	Pearson r
soft0	66.62±3.07	55.44±1.36	66.33±5.77	66.63±4.18	72.22±1.90	0.6226
soft1	75.89±2.31	56.11±1.97	60.53±8.25	76.98±2.76	76.26±3.10	0.5862

如表 4-2 所示, 在第二阶段的性能验证中, 软标签将 Acc 从 66.62%推升至 75.89%、AUROC 从 72.22%提升至 76.26%, 单从这两个指标看似已经接近 ApSense 原文水平 (Acc 75.10%、AUROC 77.64%)。但更深一层观察: F1 仍停留在 56%附近、Pearson r 不升反降, 说明软标签提升的主要是阈值平移后的二分类决策边界, 而非模型对事件本身的判别能力。作为补充验证, 本文在 delay0 上也跑了软标签实验, 结果的 6 个参数分别为 Acc=76.00±2.13%、F1=56.03±2.45%、Sens=59.67±7.64%、Spec=77.28±2.91%、AUROC=76.03±2.54%、Pearson r=0.5613, 与 delay10 的结果几乎相同, 进一步说明软标签在原始数据预处理上的收益对 delay 选择不敏感。

综合两阶段的结果, 在原始预处理上, 无论是延迟对齐还是软标签, 乃至两者的组合, 都未能在 F1 与 Pearson r 上突破 ApSense 原文水平, 这反向证明性能瓶颈并不在标签层, 而在更底层的数据层。

4.2 改进的 v2 数据预处理

4.2.1 预处理改进动机

4.1.2 节的网格扫描在标签层未能弥合性能差距, 使焦点回到数据层。回顾原始预处理流程, 存在两个被忽视的根本问题。

首先是原始预处理流程中整夜切窗未区分睡眠段和清醒段。MESA 受试者夜间记录通常包含 1 到 2 小时入睡前加 0.5 到 1 小时醒后的清醒时段，两者合计约占整夜的 15%到 25%，这些时段不可能发生 OSA 事件却被以标签=0 的形式纳入负样本，稀释了真正的睡眠中无事件的诊断含义。

再者是原始预处理流程中 Hypopnea 事件未经 AASM 临床确认。原始预处理不加区分地将所有 Hypopnea 和 Unsure 事件视为正例，根据 AASM 评分手册的临床定义^[22]，仅有伴随 Arousal（微觉醒事件）或者 SpO₂ Desaturation（血氧饱和度下降事件）才被认定为有效事件。上述这两项问题在数据层面共同造成了无效负样本污染+假阳性正样本噪声的双重失真。

为此，本文构建了 v2 预处理流程，其核心改进即 2.2 节系统介绍的两条规则，基于 XML 睡眠分期事件提取首末非清醒段、裁剪清醒时段；对 Hypopnea 和 Unsure 事件按紧邻 Arousal 或 SpO₂ Desaturation 的规则二次确认。v2 预处理的所有改动仅作用于数据层，其余的模型结构、损失函数、训练协议、超参相对原始预处理完全保持一致，从而保证 4.2.2 节的对比为严格意义上的数据消融。

4.2.2 预处理效果验证

在相同模型（DSepST15Net_no_branch）与超参下，仅将训练数据由原始预处理（v1）产物替换为 v2 预处理产物，性能跃升如表 4-2 所示。

表4-3 v1与v2预处理在基准模型下的对比（delay0+soft0）

预处理	Acc(%)	F1(%)	Sens(%)	Spec(%)	AUROC (%)	Pearson r
v1	67.74±2.61	55.95±0.92	64.29±5.69	68.19±3.64	71.92±1.75	0.5551
v2	75.27±0.85	65.49±1.31	68.36±2.30	76.60±1.18	79.91±0.96	0.7255
Δ	+7.53	+9.54	+4.07	+8.41	+7.99	+0.1704

表中数字所反映的趋势在被试级 AHI 估计图（图 4-3）中可一目了然，v2 的散点更紧密贴合 y=x 参考线，Bland-Altman^[37]一致性图（图 4-4）的 95%LoA 也明显收窄。




图4-3 v1 (左) 和v2 (右) 的散点图对比




图4-4 v1 (左) 和v2 (右) 的Bland-Altman一致性图对比

值得注意的是，首先，仅靠数据预处理改进，本方法即首次在所有指标上反超 ApSense 原文报告水平，这从经验上证明了数据质量对模型性能的决定性影响。

其次，AUROC 提升幅度 (+8.0) 显著大于 Acc 提升幅度 (+7.5)，说明 v2 预处理不仅平移了决策边界，还使得分类器在不同阈值下的整体可分性都被改善。

然后，Acc 和 Sensitivity 的 5 折标准差分别由 $\pm 2.61\%$ 、 $\pm 5.69\%$ 降至 $\pm 0.85\%$ 、 $\pm 2.30\%$ ，模型稳定性得到明显增强，这一现象的合理解释是，v1 预处理引入的清醒段噪声与未确认 Hypopnea 噪声在不同折之间分布不均，导致折间方差被放大，v2 预处理消除了这部分噪声后，受试者独立划分的折间一致性自然提升。

最后, Pearson r 从 0.5551 跃升至 0.7255 (+0.17), 这一指标增幅意味着模型在被试级 AHI 估计上获得了显著更高的临床可用性, 而 4.1 节的 delay、soft 网络搜索在该指标上几乎无任何改善。这一对比直接验证了 4.1.2 节末提出的判断: 性能瓶颈在数据层而非标签层。

4.3 延迟对齐与软标签优化

4.3.1 PPG 生理延迟补偿

在 2.3.3 节的实证分析中, 呼吸事件至 PPG 可观测响应的中位延迟为 21.3s (p25 到 p75 区间为 15.2 到 32.6s), 主体分布在 10 到 30s 区间。这一延迟由 SpO_2 去饱和通路与微觉醒通路两条生理通路共同决定^[7, 8, 15]。在标签构建侧引入正向时间偏移 delay_sec, 使标签的事件时间区间整体后移 delay_sec 秒再与 PPG 滑窗对齐, 等价于令模型学习 PPG 信号当前秒可能反映的是 delay_sec 秒前发生的事件。这一对齐操作并不改变模型本身, 而是将标签-信号响应的时序错位预先消除。

且 4.1.2 节已观察到 delay 在原始预处理下几乎无收益。重新审视这一现象在 v2 预处理基础之上是否仍然成立, 是本节的关键问题。

4.3.2 软标签训练策略

延迟对齐解决了标签什么时候出现的问题, 下一步要解决的是标签出现时强度有多大。在 2.3.2 节构建的软标签中, 对每个 60 秒滑窗, 事件覆盖比例 $\text{ratio} = \text{sum}(\text{binary}) / \text{win_size} \in [0, 1]$, 一个完整覆盖事件的窗口得到 1.0, 而像中段只发生 10 秒 Hypopnea 的窗口则得到 $1/6 \approx 0.17$ 。这种粒度差异在硬标签下会被一刀切地抹平为同一个 1, 迫使模型对覆盖 100% 与覆盖 17% 这两类完全不同强度的样本输出同等的高置信度, 实际上是把仅有 17% 事件的窗口和典型完整事件的窗口当作同一类正样本来训练, 模型在边界样本上的判别能力自然会被伤害。所以, 软标签做的事情很简单, 即让监督信号本身携带覆盖比例大小这一连续信息, 把强度差异显式交给模型去学习。

在实现层面, 软标签策略对模型架构与训练循环几乎是透明的。模型输出仍是单一 logit, 损失函数仍是 BCEWithLogitsLoss, 只是把它的目标值域从 $\{0, 1\}$ 隐

式扩展到[0,1],且由于 PyTorch 的二元交叉熵原生支持浮点目标,损失函数本体不需要修改。需要做小改动的只有标签的预处理与折间分层这一对辅助步骤,训练阶段以每窗口标签数组的 ratio 均值作为监督目标;而 5 折分层交叉验证与类别权重计算则继续以 ratio ≥ 0.5 二值化后的版本为基准,因为这两步本身只接受离散类别。这一处理保证了软、硬标签实验共享同一套受试者划分与折间分层,使得 4.3.3 节的消融对比可以在严格控制变量的前提下进行。

4.3.3 消融实验与分析

按照 v2 预处理+delay 网格*{soft0,soft1}的设置,本节系统消融延迟对齐与软标签的独立及联合贡献,结果如表 4-4 所示。

表4-4 v2预处理基础上的延迟与软标签消融 (DSepST15Net_no_branch)

配置	Acc(%)	F1(%)	Sens(%)	Spec(%)	AUROC (%)	Pearson r
v2_delay0_soft0	75.27 $\pm$	65.49 $\pm$	68.36 $\pm$	76.60 $\pm$	79.91 $\pm$	0.7255
	0.85	1.31	2.30	1.18	0.96	
v2_delay10_soft0	73.41 $\pm$	63.40 $\pm$	65.68 $\pm$	74.90 $\pm$	77.55 $\pm$	0.6777
	1.11	1.50	3.19	1.87	1.00	
v2_delay0_soft1	81.17 $\pm$	64.35 $\pm$	66.97 $\pm$	82.57 $\pm$	83.34 $\pm$	0.7866
	1.12	1.77	4.66	1.35	1.56	
v2_delay10_soft1	82.40$\pm$	65.44 $\pm$	66.22 $\pm$	83.98$\pm$	84.10$\pm$	0.8017
	1.68	1.53	6.87	2.16	1.66	

从表 4-4 中可以提炼出三层相互关联的现象。首先,最直观的一点是 delay 在硬标签与软标签下的表现大相径庭。在 v2+硬标签 (soft0) 的设置下,把 delay 从 0 推到 10 反而让 AUROC 从 79.91% 跌到 77.55%、Pearson r 从 0.7255 跌到 0.6777,呈现一种反向收益;但同样的 delay=10 一旦叠加到软标签 (soft1) 上, AUROC 立即从 83.34% 上升到 84.10%、Pearson r 从 0.7866 上升到 0.8017,转为协同正收益。这种 180° 是源于硬标签对边界对齐的高度脆弱。延迟偏移会让部分本来恰好覆盖窗口尾部的事件溢出窗口外,从而被错误地翻转为负类,给训练注入额外的标签噪声;而软标签以覆盖比例作为连续监督,事件因延迟偏移在窗口边界轻微挤压时不会突变为标签翻转,反而能让模型学习到更准确的事件中心位置。这

一现象与 2.3.3 节关于延迟分布存在长尾、单一固定 delay 不可能完美对齐所有事件的论断相互印证。软标签这类对边界宽容的监督形式，本身就是对延迟无法被任何固定值精确捕捉这一固有事实的结构性补偿。

把视野从单变量切换到三项改进的相对地位，可以看出 v2 预处理与软标签是该任务真正的主驱动因素，而 delay 更像是一个协同微调器。从原始预处理方法 (v1) 跨到 v2 仅靠数据预处理就贡献了+8 个百分点的 AUROC (4.2.2 节)，软标签在 v2 之上又贡献了约+3.4 个百分点 (79.91%到 83.34%); 相比之下 delay 在前两者已经到位时仅贡献额外+0.76 个百分点 (83.34%到 84.10%)，其边际增益不到主驱动因素的四分之一。这一相对地位的差异对后续工作的方法论意义在于，精细调参 delay 的边际收益相对有限，而真正能撬动性能上限的杠杆位于数据层 (4.2 节) 与标签层 (4.3.2 节) 这两个更上游的环节。

更进一步看，三项改进之间的协同并不是简单的线性叠加。如果 delay 与 soft 各自的效应可以独立加和，那么从单纯 v2+soft1 (AUROC=83.34%) 出发、再叠加上在 v2 上 delay 从 0 到 10 带来的-2.36 个百分点，按线性外推应退到 80.98%; 但实际观测到的却是反向上升至 84.10%。换言之，delay 的效应符号在软标签存在与否下完全相反，三项改进之间形成的是结构性而非加性的协同。v2 预处理消除噪声，为软标签提供干净的连续监督基础；软标签的边界宽容性，又为 delay 偏移提供容错空间。这条数据-标签改进链一旦缺失任何一环，剩余两环的收益便会显著缩水甚至反向，这也是后续 4.4 节多示例学习能在该链条之上继续提升的方法学前提。

至此，1.3 节标签层面的不足已得到实证回应。但表 4-4 同时也暴露了一个新问题，Sensitivity(66.22%)与 F1(65.44%)相对其余指标偏弱，且与 v2_delay0_soft0 的 Sensitivity (68.36%) 相比甚至略有下降。这表明软标签+delay 虽提升了整体 AUROC 与 Specificity，却未能进一步提升模型对真阳性的识别能力。从模型结构看，60 秒滑窗经四阶段下采样后被压缩为单一 logit，模型必须用一个标量同时承载窗口内是否有事件与事件强度两类信息，这一表达上的瓶颈在事件仅占窗口 10 到 30 秒时格外明显。这一观察自然导出 4.4 节的多示例学习方案。

4.4 基于多示例学习的事件级可解释建模

4.4.1 SIL 的时间局部性与可解释性缺失

4.3 节末已揭示,单实例学习(Single Instance Learning, SIL)框架将 60 秒滑窗压缩为单一 logit,存在两个本质局限,首先是时间局部性建模缺失,呼吸事件持续时间通常在 10 到 60 秒之间,且发生位置在窗口内是任意的,SIL 框架在窗口尺度的全局判别无法显式刻画事件位于哪几秒。其次是可解释性缺失,临床医师在使用 AI 筛查系统时往往希望获得哪几秒疑似事件的细粒度提示,以便人工复核,SIL 输出的单一概率值则不携带任何位置信息。

多示例学习(Multiple Instance Learning, MIL)范式正是为这类标签在 bag 级、判别在 instance 级的弱监督问题设计的。bag 级标签由若干 instance 共同决定,至少一个 instance 为正即整个 bag 为正^[38, 39]。本文将 60 秒滑窗自然切分为 60 个 1 秒粒度的 instance, bag 级标签由窗口内是否存在确认事件决定;通过 attention-based pooling 将 instance 级特征加权聚合为 bag 级表示,attention 权重本身即可作为哪些时间步对最终分类决策贡献最大的可解释信号^[40]。

4.4.2 DSepMIL 模型结构

DSepMIL 沿用了 DSepST15Net 的 RVarDSepBlock 作为局部时序特征抽取的基本单元,但围绕如何把 60 秒滑窗变成 60 个 1 秒粒度的 instance、再聚合为一 bag 级判决这一问题,对 backbone 深度、instance 投影、池化机制三处都做了针对性的重新设计。

模型最前端的 backbone 直接从 DSepST15Net 借来,但只保留前 2 个阶段而不是原本的 4 个。这一截短的直接动机在于时间分辨率,原 DSepST15Net 经 4 次步长 2 的 AvgPool 把时间步数压缩至 7,对应每 instance 覆盖原始约 8.6 秒,这种粗粒度对事件中心定位任务而言已严重模糊掉时间局部性。仅保留前 2 个 backbone 阶段后输出张量为(B,16,60),时间步数等于原始 60 秒、每个 instance 恰好对应 1 秒,把时间分辨率拉到了滑窗采样率的物理上限。这一截短在工程层面还带来了一个意料之外的收益,由于砍掉了后两阶段的 8 个 RVarDSepBlock 及其内嵌的 LSTM 算子,DSepMIL 的单 epoch 训练时长在同硬件、同 batch 下大致只有基准 DSepST15Net 的不到一半。这意味着即便后续在同一算力预算下做

更密集的超参扫描、消融对比、乃至面向可穿戴部署的进一步模型瘦身,也具备充足的迭代余地;而推理侧的同等量级加速也对真实部署场景下的实时性约束更为友好,这一点构成了该模型在实用价值层面的额外加分项。




图4-5 DSepMIL模型结构图

backbone 输出的(B,16,60)张量经转置后被解读为长度 60 的 instance 序列、每个 instance 的维度为 16。但 16 维对后续 attention 网络略嫌单薄,因此中间插入一层 Linear(16,64)+BatchNorm+ReLU+Dropout 把每个 instance 升至 $d_{\text{model}}=64$ 维^[33,41]。这一步本身没有创新,目的是给 attention 头一个足够的表达空间,让 score 网络在对每一秒做事件相关性打分时不被低维瓶颈卡住,便于后续的池化机制充分发挥。

真正与原版 attention-based MIL^[39]拉开差距的,是后接的平滑门控注意力池化 (Smoothed Gated Attention Pooling)。设投影后得到的 bag 表示为 $H = \{h_1, h_2, \dots, h_N\} \in R^{N \times d}$ (本文 $N=60, d=64$), 整个池化过程可以拆解为打分、平滑、归一化、聚合四步,逐次展开如下。

打分沿用 Ilse et al.的 gated-attention 设计^[39], 由两路并行的非线性投影通过逐元素相乘实现门控:

$$s_i = w^T (\tanh(Vh_i) \sigma(Uh_i)), i = 1, \dots, N \quad (8)$$

其中 $V, U \in R^{d_a \times d}$, $w \in R^{d_a}$ 为可学习参数, $d_a = 64$ 为 attention 隐藏维度, $\sigma(\cdot)$ 为 sigmoid 函数, $\odot$ 表示逐元素乘。两路在分工上各有侧重, $\tanh$ 路提供有界的特征表达, 路则扮演门的角色, 只有同时被 $\tanh$ 路视为重要、又被 sigmoid 路放行的特征维度才能贡献到最终 score, 这种双重确认机制比单路 attention 更不容易被异常 instance 误导。

紧接打分之后是 DSepMIL 真正的方法学创新点, 在对 score 序列做 softmax 之前先施加一次宽度 $k=5$ 的滑动平均:

$$\tilde{s}_i = \frac{1}{k} \sum_{j=i-\lfloor k/2 \rfloor}^{i+\lfloor k/2 \rfloor} s_j, k=5 \quad (9)$$

边界处采用与 PyTorch AvgPool1d(kernel_size=5, padding=2) 一致的零填充。这一平滑约束有明确的物理动机, 呼吸事件在时间轴上是连续波段而非离散尖峰, 临床定义下 OSA 与 Hypopnea 的最短持续时长均为 10 秒, 且 PPG 对事件的响应也以波段方式呈现 (2.3.3 节)。若放任 attention 自由训练, 模型很容易陷入局部解, 从而丧失时间局部性建模的本意; 先平滑再 softmax 强制每个时间步的 attention 权重对邻近 5 秒的 score 取平均, 使最终注意力分布天然倾向 5 秒以上的连续波段, 与事件物理特性吻合。

平滑后的 score 经标准 softmax 归一化为 attention 权重:

$$a_i = \frac{\exp(\tilde{s}_i)}{\sum_{j=1}^N \exp(\tilde{s}_j)}, \sum_{i=1}^N a_i = 1 \quad (10)$$

最后 bag 级表征由 instance 表征以 attentio 加权求和得到:

$$z = \sum_{i=1}^N a_i \cdot h_i \in R^d \quad (11)$$

聚合后的 bag 表征 $z \in R^{64}$ 进入分类头 Linear(64,32)+BatchNorm+ReLU+Dropout+Linear(32,1)^[33,41], 输出单一 logit 完成最终判决。模型在前向计算中同步保存当前 batch 的 attention 权重 $a \in R^N$ (实现层面记为 last_attention), 供 4.4.4 节进行注意力热力图的可解释性分析使用, 每一个被分类为阳性的窗口都自动附带一条模型重点关注了哪几秒的细粒度指引, 这正是 DSepMIL 区别于 SIL 单一 logit 输出的核心可解释性接口。

4.4.3 ComboFocalF1Loss 损失设计

直接将 BCEWithLogitsLoss 用于 DSepMIL 训练时, 本文观察到模式坍塌 (mode collapse) 现象, 即模型经过若干 epoch 后输出全 0 或全 1 的 attention 与 prediction, 验证集 F1 卡在 0 或者 trivially 接近 1.0 的全阳性水平。这一现象在 attention-based MIL 中较为常见, 原因是 attention 权重与分类层的耦合使梯度在初期容易将 attention 权重推至均匀分布或单一峰值, 进而导致 bag 表征退化。

为缓解模式坍塌, 本文设计 ComboFocalF1Loss, 即 Focal Loss 与 SoftF1 Loss 的加权组合。设 batch 内第 i 个样本的 logit 为 z_i 、目标软标签为 $y_i \in [0,1]$ 、sigmoid 概率为 $p_i = \sigma(z_i)$, 组合损失定义为:

$$\mathcal{L}_{\text{Combo}} = \mathcal{L}_{\text{focal}} + \lambda \cdot \mathcal{L}_{\text{SoftF1}}, \lambda = 0.5 \quad (12)$$

Focal Loss 分量, 对易分类样本降权, 迫使模型关注难分样本^[42]。引入 p_t 作为模型对真实类别的置信度:

$$p_{t,i} = \begin{cases} p_i, & \text{if } y_i > 0.5 \\ 1 - p_i, & \text{else} \end{cases} \quad (13)$$

则 Focal 分量为:

$$\mathcal{L}_{\text{focal}} = -\frac{1}{B} \sum_{i=1}^B w_i \cdot (1 - p_{t,i})^\gamma \cdot \log p_{t,i}, \gamma = 2.0 \quad (14)$$

其中 B 为 batch size, 权重 w_i 由 batch 级动态 α 决定:

$$\alpha_{\text{batch}} = \begin{cases} 1 - \frac{N_+^{(b)}}{B}, & \text{if } 0 < N_+^{(b)} < B \\ 0.5, & \text{else} \end{cases} \quad (15)$$

$$w_i = \begin{cases} \alpha_{\text{batch}}, & y_i > 0.5 \\ 1 - \alpha_{\text{batch}}, & \text{else} \end{cases} \quad (16)$$

其中 $N_+^{(b)}$ 为当前 batch 内的阳性样本数。这一动态 α 等价于以本 batch 阴性占比作为阳性权重, 自动放大阳性少数类的损失贡献, 相对固定 α 的常规 Focal Loss 在数据级类别比例随 batch 波动时更稳定。

SoftF1 Loss 分量, 是 F1 分数的可微分代理^[43]。直接将 sigmoid 概率代入 TP、FP、FN 的连续近似:

$$\widetilde{TP} = \sum_{i=1}^B p_i y_i \quad (17)$$

$$\widetilde{FP} = \sum_{i=1}^B p_i(1 - y_i) \quad (18)$$

$$\widetilde{FN} = \sum_{i=1}^B (1 - p_i) y_i \quad (19)$$

$$\mathcal{L}_{\text{SoftF1}} = 1 - \frac{2\widetilde{TP} + \varepsilon}{2\widetilde{TP} + \widetilde{FP} + \widetilde{FN} + \varepsilon}, \varepsilon = 10^{-7} \quad (20)$$

该项对模式坍塌的两种典型退化解给予直接惩罚：全阴性预测（ p_i 趋近于 0）使 $\widetilde{TP}$ 趋近于 0，从而 $\mathcal{L}_{\text{SoftF1}}$ 趋近于 1；全阳性预测（ p_i 趋近于 1）使 $\widetilde{FP}$ 极大，同样使 $\mathcal{L}_{\text{SoftF1}}$ 趋近于 1。两种极端都被显式惩罚，从机制上抑制 attention-MIL 训练的早期坍塌。组合权重 λ 经验确定，使两项分量在训练初期处于同一数量级。

此外，DSepMIL 训练阶段额外引入梯度裁剪以稳定优化^[44]，该步在 RVarDSepBlock 内嵌的 LSTM 上尤为必要，可显著降低早期 epoch 的训练 loss 抖动。

4.4.4 实验结果与可解释性分析

表4-5 DSepMIL与DSepST15Net基线在v2预处理上的对比

模型	配置	Acc (%)	F1 (%)	Sens (%)	Spec (%)	AUROC (%)	Pearson r
DSepST15Net	v2_delay10_soft1	82.40	65.44	66.22	83.98	84.10 ± 1.66	0.8017
		±	±	±	±		
		1.68	1.53	6.87	2.16		
DSepMIL	v2_delay0_soft0	79.57	68.24	61.62	82.94	80.85 ± 0.76	0.7668
		±	±	±	±		
		1.59	0.86	4.40	2.35		
DSepMIL	v2_delay10_soft0	76.76	65.79	62.66	79.40	78.94 ± 1.10	0.6995
		±	±	±	±		
		1.99	1.58	4.48	2.98		
DSepMIL	v2_delay0_soft1	80.35	64.13	70.28	81.31	83.48 ± 2.15	0.7964
		±	±	±	±		
		1.78	1.80	5.61	2.28		
DSepMIL	v2_delay10_soft1	81.34	65.22	70.98	82.35	84.96 ± 1.58	0.8075
		±	±	±	±		
		1.26	1.69	4.27	1.45		

表 4-5 末行 SIL 与 MIL 的逐指标对比可借图 4-5 直观呈现：MIL 在被试级 AHI 估计上的散点向 $y=x$ 收拢、Bland-Altman 偏差均值更靠近 0，与 Pearson r 从 0.8017 到 0.8075 的提升一致。




图4-6 v2_delay10_soft1设置下DSepST15Net（左）与 DSepMIL（右）的散点图对比




图4-7 v2_delay10_soft1设置下DSepST15Net（左）与 DSepMIL（右）的Bland-Altman图对比

观察 DSepMIL 与 DSepST15Net 基线在 v2 预处理上的对比实验结果，MIL 在 v2_delay10_soft1 指标下的 AUROC (84.96) 与 Pearson r (0.8075) 两项指标上同时刷新全部实验最优值，且后者的提升尤为重要，Pearson r 衡量预测窗口阳性率与真实 AHI 的线性相关性，是被试级 AHI 估计的核心代理指标，直接对应临床筛查报告中是否患有 OSA 及其严重程度的诊断结论。从 0.8017 到 0.8075 看

似仅提升 0.0058, 但考虑到该指标的标准差也仅 ± 0.015 量级, 这一改进具备统计可观察性, 且代表性能曲线已逼近受试者级别的内禀上限。

其次, Sensitivity 指标由 DSepST15Net 的 66.22% 跃升至 70.98% (+4.76), 改善幅度大于其他任何指标。这一现象正面回应了 4.3.3 节末提出的问题, DSepST15Net 的单 logit 瓶颈在 Sensitivity 维度上的表现相对其他维度更弱, 而 MIL 的 instance 级建模通过保留时间分辨率缓解了这一瓶颈, 使模型能更充分地看到窗口内的局部事件证据。这一提升在临床筛查场景中具有直接价值, 高 Sensitivity 意味着模型不易漏检阳性, 对先用 PPG 初筛、再用 PSG 确诊的两级筛查路径而言, 初筛阶段的 Sensitivity 比 Specificity 更值得优化。

然后, DSepMIL 在硬标签下 (v2_delay0_soft0) 已达到 $F1=68.24\pm 0.86\%$, 在所有配置中最高, 说明 MIL 的结构改进本身具备独立提升能力, 即使不叠加软标签也能带来收益; 而软标签则进一步将 AUROC 由 80.85 推升至 84.96, 二者形成建模层与标签层的协同。

最后, 注意力可视化证实了 MIL 的可解释性优势。本文从测试集中按 MIL 预测概率从高到低挑选了 5 例正确识别的呼吸事件 (4 例 Hypopnea/Unsure 来自 $AHI=53.21$ 的重度 OSA 受试者 6413, 1 例 Obstructive Apnea 来自 $AHI=28.94$ 的受试者 0485), 绘制了每个窗口的 attention 权重曲线, 如图 4-8 所示。

所有 5 例的预测概率都在 0.995 以上, 模型判决高度自信。典型现象是 attention 峰值与事件真实时段高度重合, 且因 AvgPool 平滑约束的存在, attention 形成持续若干秒宽度的连续波段而非孤立尖峰, 这正是 4.4.2 节平滑门控注意力的设计意图。这说明模型不再只输出窗口阳性概率, 而是同时给出重点关注的时间段这一细粒度的事件时间线索。这是 SIL 框架的单一 logit 输出在结构上无法提供的信息。

需指出的是, DSepMIL 在 Specificity (82.35) 与 Accuracy (81.34) 两项指标上略低于最优 SIL (分别为 83.98 和 82.40), 这一 1 到 2 个百分点的差距是 MIL 结构换取 Sensitivity 与 Pearson r 提升的代价。在筛查场景下, 这种以 Specificity 略减换 Sensitivity 显著增加的权衡通常被认为是有益的, 对先用 PPG 初筛、再用 PSG 确诊的两级路径而言, 初筛阶段宁可放过一定特异性, 也要保证敏感性充分。




图4-8 DSepMIL注意力权重曲线的5例典型展示
(阴影为事件真实区段)

4.5 综合结果讨论与多维度案例分析

4.5.1 三阶段改进的定量消融总表

将 4.1 到 4.4 节代表性实验汇总为表 4-5,可清晰看到本文沿基准复现、数据、标签、建模四阶段递进的性能提升轨迹。

阶段间核心指标的递进式提升一目了然: AUROC 从 71.92%到 79.91%再到 84.10%最后到 84.96%,提升了 13.04%; Pearson r 从 0.5551 到 0.7255 再到 0.8017 最后到 0.8075,提升了 0.2524。其中 Pearson r 提升幅度的相对意义最为重要,该指标从 0.5551 的中等相关跃升到了 0.8075 的强相关,意味着模型从勉强有趋势演化为可作 AHI 估计代理,跨越了临床应用的关键阈值。

本方法在 Sensitivity 上甚至超过 ApSense 原文(70.98vs61.71,且原文标准差 ± 17.41 极大),且本文 5 折标准差降至 ± 4.27 ,鲁棒性提升幅度同样显著,这一指标的改善归因于 v2 预处理对噪声标签的过滤(折间一致性)以及 MIL 的时间局部性建模(事件级证据保留)。综合 AUROC、Pearson r、Sens、稳定性四项核

心指标，本文方法在 MESA 数据集上对 ApSense 实现了全面超越，且每一阶段的改进都对应 1.3 节提出的某一具体不足，形成了动机、方案、验证的完整研究闭环。

表4-6 三阶段递进改进的完整消融总表

阶段	配置	Acc (%)	F1 (%)	Sens (%)	Spec (%)	AUROC (%)	Pearson r
原始	Apsense (参考)	75.10	65.73	61.71	78.46	77.64	未给出
论文		± 2.70	± 4.84	± 17.4	± 1.62	± 7.93	
基准	v1_delay0_soft0	67.74	55.95	64.29	68.19	71.92	0.5551
复现		± 2.61	± 0.92	± 5.69	± 3.64	± 1.75	
v2	v2_delay0_soft0	75.27	65.49	68.36	76.60	79.91	0.7255
预处理		± 0.85	± 1.31	± 2.30	± 1.18	± 0.96	
+软标签	v2_delay10_soft1	82.40	65.44	66.22	83.98	84.10	0.8017
+delay		± 1.68	± 1.53	± 6.87	± 2.16	± 1.66	
	v2_delay10_soft1	81.34	65.22	70.98	82.35	84.96	0.8075
+MIL	_DSepMIL	± 1.26	± 1.69	± 4.27	± 1.45	± 1.58	




图4-9 四阶段方法在被试级AH1估计上的散点矩阵 1
左：基准复现 (r=0.5551)；右：+v2预处理 (r=0.7255)




图4-10 四阶段方法在被试级AH1估计上的散点矩阵 2
左: +软标签+delay ($r=0.8017$) ; 右: +MIL ($r=0.8075$)

4.5.2 MIL 注意力的正案例分析

为定性印证 MIL 注意力机制的有效性, 本节选取一例在 SIL 基线 (DSepST15Net) 下被漏检 (预测概率 <0.4) 但被 DSepMIL 正确识别 (预测概率 0.971) 的 Hypopnea 事件作为正案例, 如图 4-11 所示。




图4-11 SIL漏检、DSepMIL正确识别的Hypopnea事件
(subj 6322, 21.4s Hypopnea, 36%覆盖, MIL预测概率0.971)

该案例来自重度 OSA 受试者 6322 (AHI=59.03)，事件位于其睡眠阶段第 21060 秒前后，持续 21.4 秒，覆盖 60 秒窗口的后半段（第 37.1 到 58.5 秒，约 35.7%覆盖率），同步 SpO₂ 由 98%跌至 87%、下降幅度高达 11 个百分点。如图 4-9 所示，三联图的上子图为 60 秒窗口的 PPG 波形并以红色阴影标注事件区段，中子图为同时段 SpO₂ 序列，下子图为 DSepMIL 输出的 60 维 attention 权重曲线。

从 attention 曲线可以读出几件相互印证的事。首先是其主峰几乎完整覆盖了事件真实区间（约第 37 到 58 秒），表明 MIL 准确捕捉到了 PPG 形态变化最显著的时段。这条主峰在 AvgPool 平滑约束的作用下呈现为一段连续波段而非孤立尖峰，宽度恰与事件物理持续时长相吻合，呼应了 4.4.2 节平滑设计所追求的事件波段特征。与之形成对照的是窗口前半段，那段事件未发生的时间内，attention 权重退回到接近均匀的低值水平，说明模型并未把无关时段误判为事件段。值得特别注意的是，事件本体位于窗口后半端而非中央，若是 SIL 单 logit 框架，这种边界位置往往意味着事件信号会被前半段大段正常呼吸稀释，从而导致整窗判为阴性。这正是 SIL 在该案例上失败的根本原因，而 MIL 通过把 attention 权重集中分配给后半段，等效于让事件证据在聚合前被放大而不是被前段稀释，最终成功救回。

将此案例对照 3.5.3 节负案例，第三章 ML 因全局聚合无法刻画事件位置而失败，第四章 MIL 通过 attention 显式定位事件位置而成功。这正是本文在 1.3 节建模层面提出的核心问题，并在 4.4 节通过 MIL 范式得以实质性解决的实证体现。

4.5.3 MIL 漏检负案例分析

尽管 DSepMIL 在整体性能上达到全实验最优，仍有一类困难样本被持续漏检。本节选取一例典型负案例进行诊断分析：受试者 4000 (AHI=29.7, 中度 OSA) 的一段 13.2 秒 Hypopnea 事件，事件落在 60 秒窗口的第 36.7 到 49.9 秒（约 22%覆盖率），同步 SpO₂ 仅由 95%跌至 92%、降低了 3%。DSepMIL 给出的预测概率仅 0.0002，是高度自信地判错，如图 4-12 所示。




图4-12 DSepMIL仍漏检的困难样本
(subj 4000, 13.2s Hypopnea, 22%覆盖, MIL预测概率0.0002)

分析 MIL 在此案例上失败原因, 其一是事件覆盖率极低且偏窗口尾端, 事件本体仅占窗口约 22%, 且位置偏后 (从第 36.7 到 49.9 秒), 事件期之外的 47 秒正常呼吸信号几乎主导了模型的整体感知; attention 权重在事件区间未能形成明显峰值, 可见 MIL 的平滑注意力机制在此类极低覆盖+边界位置的样本上难以聚焦。其二是短事件持续时长与平滑窗口大小相近, 13.2 秒事件仅是 4.4.2 节 5 秒 AvgPool 平滑核宽度的 2.64 倍, 相邻位置之间的 score 差异在平滑后被进一步抹平, 模型难以将事件区段与自然呼吸节律的小幅波动区分开。其三是单模态 PPG 信号信息有限, SpO₂ 仅下降 3%, 对应的 PPG 形态扰动也相应微弱, 几乎接近正常呼吸的自然波动量级; 本文方法所依赖的 7 通道脉搏级形态特征在此类临界事件上信号信噪比偏低。

综合上述三个失败原因, 本文方法的边界集中在两个层面。结构层面, 当事件覆盖率极低 (<25%) 且偏向窗口边界、或持续时长本身就接近 5 秒平滑核的 2 到 3 倍时, MIL 的平滑注意力机制反而成为掣肘。它原本是为捕捉连续事件波段而设计, 遇到极短或极偏的事件就会把本就微弱的事件期权重进一步抹平。模态层面则是更根本的瓶颈。当 SpO₂ 响应仅在 AASM 3% 阈值附近时, PPG 形态扰动相应也微弱, 单模态信号本身就接近噪声水平。

5 总结与展望

5.1 研究工作总结

本文围绕基于 PPG 的睡眠呼吸暂停检测这一临床场景展开,从对 ApSense 基线的复现起步^[15],沿数据、标签、建模三个层面递进改进,最终在 MESA 数据集上把被试级 AHI 估计能力从中等相关推进到强相关。

第二章回到了所有问题的源头,也就是数据本身。原始 ApSense 流程对 MESA 整夜记录采用一刀切 30 分钟首尾裁剪清醒段的策略,在实际数据上既会保留大量真正的清醒期,也会误伤入睡快的受试者;它同时把 EventConcept 中含 Hypopnea 的事件不加区分地全部纳入正样本,引入了不符合 AASM 临床判据的标签噪声。本文据此提出 v2 预处理流程,以 XML 睡眠分期事件精确提取每位受试者的有效睡眠时窗,并对 Hypopnea、Unsure 候选事件按紧邻 Arousal 或 SpO₂ 下降规则^[22]做二次确认,丢弃不满足条件的约 15%事件标注。仅此一项数据层改进,便让 ApSense 基准模型的 Acc 从复现的 67.74%提升至 75.27%、AUROC 从 71.92%提升至 79.91%、Pearson r 从 0.5551 提升至 0.7255,且 5 折标准差由 $\pm 2.6\%$ 缩窄至 $\pm 0.9\%$ 。这一结果验证了一个朴素却常被忽略的事实:在临床信号建模任务中,数据质量的提升所带来的收益往往大于模型结构的精巧化。

标签层面的改进围绕两个事实展开:呼吸事件在窗口内的时间覆盖比例不固定,以及 PPG 信号对事件的响应存在中位约 21 秒的生理延迟(2.3.3 节)。本文以事件覆盖比例 $\text{ratio} \in [0,1]$ 替代硬二值标签,让模型直接对事件占据窗口比例大小建模;并通过对标签时间轴施加 10 秒前移补偿 PPG 响应延迟。在 v2 预处理之上叠加这两项调整,Acc 进一步推升至 82.40%、AUROC 至 84.10%、Pearson r 至 0.8017。值得一提的是,硬标签下 delay 几乎无收益、软标签下才显现协同,三项改进之间存在非线性的协同效应,不可任意拆分。单独评估每一项改进的边际贡献并不足以指导选择,需要在正确的组合上下文中观察才能看到真实价值。

建模层面最终落到使用多示例学习的 DSepMIL 模型,它把 60 秒滑窗自然切分为 60 个 1 秒粒度的 instance,借助本文设计的平滑门控注意力池化在 score 上施加 5 步均值平滑后再 softmax,从结构上强制注意力形成连续波段,契合呼吸事件 10 到 60 秒的物理持续时长。配合为抑制 attention-MIL 训练 mode collapse 而设计的 ComboFocalF1Loss,最终模型在与 SIL (DSepST15Net) 同样的

v2+delay10+soft1 设置下达到 Acc 81.34%、AUROC 84.96%、Pearson r 0.8075、Sens 70.98%的成绩,且 AUROC 与 Pearson r 两项指标同时刷新全部实验最优值, Sens 相比 SIL (DSepST15Net) 基线跃升 4.76%。更重要的是,注意力权重热力图对事件区段形成可视化的局部聚焦,给临床医师提供了疑似事件时间位置的细粒度提示,这是 SIL (DSepST15Net) 的单一 logit 输出在结构上无法提供的信息。

作为对照,第三章用事件中心采样+49 维统计特征+SVM、决策树、随机森林这条传统机器学习路线给出了同任务下的性能参照 (AUROC $\approx$ 73%)。这条对照线的价值并不只在于一个数字,机器学习方法的负案例分析揭示了一个比低覆盖+弱信号更深的问题,两个事件参数几乎对等的窗口 (30 秒持续、50%覆盖、8~9%SpO₂ 下降),可以因受试者个体的 PPG 形态响应差异而获得截然相反的预测结论。这一现象暴露了基于 PPG 单模态、全局聚合的 49 维特征体系在面对临界 OSA 患者时的固有脆弱性,也直接论证了端到端深度特征学习与 MIL 时间局部建模的必要性。

5.2 不足与展望

尽管本文方法在 MESA 上取得了可观的改进,但要把它从研究原型推向真实可部署的可穿戴筛查产品,仍有若干局限需要在后续工作中逐项突破。

单数据集验证带来的泛化性疑问。本文所有实验均在 MESA 一个数据集上完成,受试者来自相对统一的人群与采集条件;模型在该数据集上学到的 PPG 形态规律未必能直接迁移到其它人群、其它采集设备。后续工作需要在 SHHS、HeartBEAT 等独立数据集上做受试者完全独立的跨域验证^[45];若性能出现明显衰减,则需进一步引入跨数据集联合训练、或基于对抗学习的 domain adaptation 技术^[46],才能确认方法具备真正的可推广性。

MIL 平滑窗口的固定取值是一个具体的方法学局限。4.4.2 节把平滑窗口大小统一设为 5 秒,这对 10 到 60 秒的典型事件适用,但对持续 11 秒上下的极短 OSA 事件 (4.5.3 负案例) 反而会因平滑半径接近事件本体长度而稀释 attention 峰值。一个改进方向是引入多尺度注意力,在同一模型内部并行设置多个不同平滑窗口大小的 attention 头,再让网络自行学习对不同时长事件的尺度选择。

单模态 PPG 的信息上限是 3.5.3 节负案例最直接揭示的问题。当 PPG 形态对事件的响应在个体层面较弱时,仅靠 7 通道形态特征 (无论由统计聚合还是深度

网络提取)都难以捕捉事件证据;而同时段的 SpO_2 序列其实已经给出了清晰的下降信号。一条直接但需要谨慎设计的改进路径是把 SpO_2 通道作为第 8 路输入与 PPG 形态并行喂入网络,让模型同时利用 PPG 的高时间分辨率与 SpO_2 的明确事件证据。然而 SpO_2 自身有大约 1Hz 的低采样率与显著的生理延迟(2.3.3 节实证统计中位 21.3 秒),如何在时间对齐与跨模态特征融合层做合理的架构设计,例如时间对齐的多尺度卷积、或基于 cross-attention 的迟到模态融合,是一个值得专门展开的子题。

AHI 估计的间接性是评价体系层面的一个缺口。本文目前以测试窗口阳性率作为受试者级 AHI 的代理预测,与真实 AHI 之间是经验线性回归而非直接事件计数。利用 MIL 输出的 attention 权重做事件级定位、再聚合为 AHI 的直接估计,理论上可以提供更贴近临床定义的 AHI 预测,这条路径在本文 4.4.4 节的注意力可视化中已有雏形,但尚未形式化为端到端的事件回归任务。一个可行的下一步是在现有 DSepMIL 输出之上额外接一个事件级解码头,把 attention 权重曲线视为事件得分序列、通过阈值化+非极大值抑制提取离散事件位置,再以每小时事件数为目标做端到端回归。

整体而言,本文沿数据、标签、建模三个层面所做的工作只是一个起点。上面列出的不足与展望本质上仍可归入这同样的三层框架。数据层(跨数据集泛化)、标签层(事件级直接回归)、建模层(多模态融合、自适应注意力),都是后续值得长期投入的研究目标。

参考文献

- [1] Parish J M, Somers V K. Obstructive sleep apnea and cardiovascular disease. Mayo Clinic Proceedings,2004,79(8):1036-1046
- [2] Young T, Skatrud J, Peppard P E. Risk factors for obstructive sleep apnea in adults. Jama,2004,291(16):2013-2016
- [3] Chen T, Zhang J, Xu Z, et al. Energy-efficient sleep apnea detection using a hyperdimensional computing framework based on wearable bracelet photoplethysmography. IEEE Transactions on Biomedical Engineering,2024,71(8):2483-2494
- [4] Benjafield A V, Ayas N T, Eastwood P R, et al. Estimation of the global prevalence and burden of obstructive sleep apnoea: a literature-based analysis. The Lancet Respiratory Medicine,2019,7(8):687-698
- [5] Newell J, Mairesse O, Verbanck P, et al. Is a one-night stay in the lab really enough to conclude? First-night effect and night-to-night variability in polysomnographic recordings among different clinical population samples. Psychiatry Research,2012,200(2-3):795-801
- [6] Roebuck A, Monasterio V, Geder E, et al. A review of signals used in sleep analysis. Physiological Measurement,2014,35(1):R1-R57
- [7] Allen J. Photoplethysmography and its application in clinical physiological measurement. Physiological Measurement,2007,28(3):R1-R39
- [8] Nilsson L M. Respiration signals from photoplethysmography. Anesthesia & Analgesia,2013,117(4):859-865
- [9] Chen Y, Wang W, Guo Y, et al. A single-center validation of the accuracy of a photoplethysmography-based smartwatch for screening obstructive sleep apnea. Nature and Science of Sleep,2021,13:1533-1544
- [10] Wang S, Xuan W, Chen D, et al. Machine learning assisted wearable wireless device for sleep apnea syndrome diagnosis. Biosensors,2023,13(4):483
- [11] Johansson A. Neural network for photoplethysmographic respiratory rate monitoring. Medical and Biological Engineering and Computing,2003,41(3):242-248
- [12] Motin M A, Karmakar C K, Palaniswami M. Ensemble empirical mode decomposition with principal component analysis: A novel approach for extracting

- respiratory rate and heart rate from photoplethysmographic signal. *IEEE Journal of Biomedical and Health Informatics*,2017,22(3):766-774
- [13]Karlen W, Raman S, Ansermino J M, et al. Multiparameter respiratory rate estimation from the photoplethysmogram. *IEEE Transactions on Biomedical Engineering*,2013,60(7):1946-1953
- [14]Garde A, Karlen W, Ansermino J M, et al. Estimating respiratory and heart rates from the correntropy spectral density of the photoplethysmogram. *PLoS One*,2014,9(1):e86427
- [15]Choksatchawathi T, Sawadwuthikul G, Thuwajit P, et al. Apsense: Data-driven algorithm in PPG-based sleep apnea sensing. *IEEE Internet of Things Journal*,2024,11(20):33915-33926
- [16]Jothi E S J, Anitha J, Hemanth D J. A photoplethysmography-based diagnostic support system for obstructive sleep apnea using deep learning approaches. *Computers and Electrical Engineering*,2022,102:108279
- [17]Jiang X, Ren Y, Wu H, et al. Convolutional neural network based on photoplethysmography signals for sleep apnea syndrome detection. *Frontiers in Neuroscience*,2023,17:1222715
- [18]Shuzan M N I, Chowdhury M H, Alam S B, et al. PPG2RespNet: a deep learning model for respirational signal synthesis and monitoring from photoplethysmography (PPG) signal. *Physical and Engineering Sciences in Medicine*,2024,47(4):1705-1722
- [19]Charlton P H, Bonnici T, Tarassenko L, et al. An assessment of algorithms to estimate respiratory rate from the electrocardiogram and photoplethysmogram. *Physiological Measurement*,2016,37(4):610-626
- [20]Guo Z, Ding C, Hu X, et al. A supervised machine learning semantic segmentation approach for detecting artifacts in plethysmography signals from wearables. *Physiological Measurement*,2021,42(12):125003
- [21]Pereira T, Gadhoumi K, Ma M, et al. A supervised approach to robust photoplethysmography quality assessment. *IEEE Journal of Biomedical and Health Informatics*,2019,24(3):649-657
- [22]Berry R B, Brooks R, Gamaldo C, et al. AASM scoring manual updates for 2017 (version 2.4). Darien:American Academy of Sleep Medicine,2017:665-666

- [23]Makowski D, Pham T, Lau Z J, et al. NeuroKit2: A Python toolbox for neurophysiological signal processing. Behavior Research Methods,2021,53(4):1689-1696
- [24]Elgendi M. On the analysis of fingertip photoplethysmogram signals. Current Cardiology Reviews,2012,8(1):14-25
- [25]Virtanen P, Gommers R, Oliphant T E, et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. Nature Methods,2020,17(3):261-272
- [26]Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research,2011,12:2825-2830
- [27]Cortes C, Vapnik V. Support-vector networks. Machine Learning,1995,20(3):273-297
- [28]Breiman L, Friedman J, Olshen R A, et al. Classification and regression trees. Boca Raton:Chapman and Hall/CRC,2017
- [29]Breiman L. Random forests. Machine Learning,2001,45(1):5-32
- [30]Fawcett T. An introduction to ROC analysis. Pattern Recognition Letters,2006,27(8):861-874
- [31]Kingma D P, Ba J. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980,2014
- [32]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2016:770-778
- [33]Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. Proceedings of the 32nd International Conference on Machine Learning,2015:448-456
- [34]Chollet F. Xception: Deep learning with depthwise separable convolutions. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2017:1251-1258
- [35]Gal Y, Ghahramani Z. A theoretically grounded application of dropout in recurrent neural networks. Advances in Neural Information Processing Systems,2016,29:1019-1027
- [36]Hochreiter S, Schmidhuber J. Long short-term memory. Neural Computation,1997,9(8):1735-1780

- [37]Bland J M, Altman D G. Statistical methods for assessing agreement between two methods of clinical measurement. *International Journal of Nursing Studies*,2010,47(8):931-936
- [38]Maron O, Lozano-Pérez T. A framework for multiple-instance learning. *Advances in Neural Information Processing Systems*,1997,10:570-576
- [39]Ilse M, Tomczak J, Welling M. Attention-based deep multiple instance learning. *Proceedings of the 35th International Conference on Machine Learning*,2018:2127-2136
- [40]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. *Advances in Neural Information Processing Systems*,2017,30:5998-6008
- [41]Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*,2014,15(1):1929-1958
- [42]Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision*,2017:2980-2988
- [43]Bénédic G, Koops V, Odijk D, et al. SigmoidF1: A smooth F1 score surrogate loss for multilabel classification. *arXiv preprint arXiv:2108.10566*,2021
- [44]Pascanu R, Mikolov T, Bengio Y. On the difficulty of training recurrent neural networks. *Proceedings of the 30th International Conference on Machine Learning*,2013:1310-1318
- [45]Zhang G Q, Cui L, Mueller R, et al. The National Sleep Research Resource: towards a sleep data commons. *Journal of the American Medical Informatics Association*,2018,25(10):1351-1358
- [46]Ganin Y, Lempitsky V. Unsupervised domain adaptation by backpropagation. *Proceedings of the 32nd International Conference on Machine Learning*,2015:1180-1189

致谢

时光荏苒，四年的大学生活即将画上句号。在本论文完成之际，我想向所有给予我帮助和支持的人致以诚挚的感谢。

首先，衷心感谢葛俊锋老师和桂康老师。在论文选题、研究思路以及论文撰写过程中，老师们始终给予我耐心细致的指导。无论是在研究方向上的把握，还是在实验与修改过程中的建议，都让我受益匪浅。导师严谨认真的治学态度也让我深受启发。

其次，感谢储檀学长在课题研究过程中给予我的帮助。学长不仅认真地为我提出了许多宝贵建议，还耐心地为我讲解数据集相关内容，并在研究思路给予我启发，使我对 MIL 方法有了更加深入的理解。这些帮助对论文的顺利完成起到了重要作用。

同时，也感谢我的朋友们四年来的陪伴与支持。尽管天各一方，但是在网络的世界里我们还是亲若比邻。在学习和生活中，你们给予了我许多鼓励与温暖，让我的大学时光充满了珍贵的回忆。

最后，感谢所有关心、帮助过我的老师、同学与家人。谨以此文，为我的大学生活留下一个阶段性的总结，也祝愿未来的自己能够继续保持热爱与探索精神，不断前行。